

# Procedimiento y análisis de datos

Amparo Galvez Vilar

2025-02-20

## Contents

<b>1</b>	<b>CARGA DE LIBRERÍAS</b>	<b>1</b>
<b>2</b>	<b>CARGA DE DATOS E INSPECCION INICIAL</b>	<b>2</b>
<b>3</b>	<b>RECODIFICAR LAS VARIABLES</b>	<b>3</b>
<b>4</b>	<b>LIMPIEZA DE DATOS</b>	<b>4</b>
4.1	Distribución variables sociodemográficas . . . . .	7
4.2	Equilibrio Escenario . . . . .	11
4.3	Tasa global Showrooming . . . . .	12
4.4	Distribución Escalas Likert . . . . .	19
<b>5</b>	<b>PROPIEDADES PSICOMETRICAS</b>	<b>20</b>
5.1	Realismo escenario . . . . .	20
5.2	Chequeo de confianza percibida . . . . .	22
5.3	Chequeo de servicio percibido . . . . .	22
5.4	Análisis Factorial Confirmatorio y propiedades psicométricas . . . . .	23
<b>6</b>	<b>ANÁLISIS EXPLORATORIO</b>	<b>27</b>
6.1	Estadísticos descriptivos y matriz de correlaciones . . . . .	27
<b>7</b>	<b>MODELO DE REGRESIÓN LOGÍSTICA</b>	<b>34</b>
7.1	Modelo inicial: sólo las cinco variables clave . . . . .	34
7.2	Ampliar con variables sociodemográficas . . . . .	35
7.3	Probar interacciones entre variables clave y demográficas . . . . .	36
7.4	Probar interacciones entre variables clave . . . . .	37
7.5	Modelo Final . . . . .	39
<b>8</b>	<b>BONDAD DEL AJUSTE DEL MODELO FINAL</b>	<b>40</b>
<b>9</b>	<b>INTERPRETACIÓN DE RESULTADOS</b>	<b>42</b>
9.1	Global . . . . .	42
9.2	Orientación al precio x Grupo de edad . . . . .	44
9.3	Gratificación x Tamaño de municipio . . . . .	45

## 1 CARGA DE LIBRERÍAS

```
library(car)
library(dplyr)
library(emmeans)
```

```
library(GGally)
library(gmodels)
library(grid)
library(lavaan)
library(likert)
library(pROC)
library(psych)
library(RColorBrewer)
library(readr)
library(reshape2)
library(ResourceSelection)
library(scales)
library(semTools)
library(tibble)
library(tidyverse)
```

## 2 CARGA DE DATOS E INSPECCION INICIAL

```
df <- read_delim("~/uni/CUARTO/segundi_cuatri/TFG/data/Datos_Amparo_FINAL_COPIA.csv",
  delim = ";", escape_double = FALSE, trim_ws = TRUE)
```

```
glimpse(df) # Muestra tipos de cada columna y primeros valores
```

```
## Rows: 720
## Columns: 24
## $ REGISTRO <dbl> 77, 79, 106, 109, 112, 115, 117, 119, 120, 130, 132, 133, 1~
## $ DURACION <dbl> 379, 347, 220, 524, 337, 368, 551, 284, 562, 468, 248, 203, ~
## $ ESTADO <dbl> 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, ~
## $ S2 <dbl> 1, 2, 1, 2, 1, 2, 1, 1, 1, 2, 2, 1, 2, 1, 2, 2, 1, 2, ~
## $ AGE <dbl> 57, 47, 64, 43, 48, 55, 62, 52, 64, 56, 61, 61, 62, 56, 55, ~
## $ CUOTA_EDAD <dbl> 3, 2, 3, 2, 2, 3, 3, 3, 3, 3, 3, 3, 3, 3, 3, 3, 3, 3, ~
## $ S3 <dbl> 7, 7, 7, 6, 7, 7, 6, 5, 7, 7, 7, 7, 7, 6, 7, 7, 7, 7, ~
## $ P1 <dbl> 3, 4, 4, 4, 3, 3, 4, 4, 4, 2, 3, 2, 4, 3, 3, 4, 4, 4, ~
## $ P2 <dbl> 2, 3, 4, 4, 2, 2, 4, 4, 4, 2, 4, 2, 4, 2, 3, 2, 3, 4, ~
## $ ESCENARIO <dbl> 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, ~
## $ P3 <dbl> 2, 2, 1, 1, 2, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 2, ~
## $ P4 <dbl> 7, 5, 5, 5, 5, 7, 7, 6, 7, 7, 6, 5, 6, 4, 4, 6, 5, 4, ~
## $ P5_1 <dbl> 2, 2, 1, 2, 2, 1, 2, 2, 2, 2, 2, 1, 1, 2, 2, 2, 2, 2, ~
## $ P5_2 <dbl> 1, 2, 2, 2, 2, 2, 1, 2, 2, 2, 2, 2, 1, 2, 2, 1, 2, 2, ~
## $ P6_1 <dbl> 6, 4, 5, 5, 5, 5, 4, 5, 5, 6, 5, 6, 4, 5, 5, 5, 6, 3, ~
## $ P6_2 <dbl> 2, 3, 4, 4, 3, 3, 2, 4, 4, 6, 5, 6, 5, 4, 5, 4, 4, 5, ~
## $ P6_3 <dbl> 6, 5, 5, 4, 4, 5, 2, 5, 6, 6, 7, 6, 5, 4, 5, 6, 5, 6, ~
## $ P7_1 <dbl> 7, 6, 5, 4, 6, 6, 4, 6, 6, 6, 7, 5, 7, 7, 5, 5, 5, 7, ~
## $ P7_2 <dbl> 5, 5, 4, 3, 5, 6, 4, 6, 6, 5, 7, 5, 7, 7, 4, 5, 5, 6, ~
## $ P7_3 <dbl> 3, 5, 4, 5, 5, 5, 5, 6, 5, 6, 7, 4, 7, 5, 6, 5, 5, 6, ~
## $ P7_4 <dbl> 4, 5, 4, 6, 4, 6, 4, 6, 4, 6, 7, 5, 7, 6, 6, 5, 4, 6, ~
## $ P8_1 <dbl> 1, 1, 4, 4, 3, 2, 3, 4, 4, 2, 3, 4, 4, 4, 3, 5, 4, 5, ~
## $ P8_2 <dbl> 1, 1, 4, 4, 2, 4, 3, 5, 4, 2, 3, 4, 6, 4, 6, 5, 5, 3, ~
## $ P8_3 <dbl> 1, 1, 4, 2, 3, 4, 3, 5, 4, 2, 3, 4, 5, 4, 6, 5, 5, 3, ~
```

```
summary(df) # Estadísticos básicos de cada variable
```

```
##      REGISTRO      DURACION      ESTADO      S2      AGE
```

```
## Min. : 77.0 Min. :180.0 Min. :1.000 Min. :1.0 Min. :18.00
## 1st Qu.: 306.8 1st Qu.:216.8 1st Qu.:1.000 1st Qu.:1.0 1st Qu.:31.00
## Median : 567.5 Median :274.5 Median :1.000 Median :1.5 Median :43.00
## Mean : 781.5 Mean :307.7 Mean :1.144 Mean :1.5 Mean :42.64
## 3rd Qu.:1247.2 3rd Qu.:358.0 3rd Qu.:1.000 3rd Qu.:2.0 3rd Qu.:55.00
## Max. :1880.0 Max. :926.0 Max. :5.000 Max. :2.0 Max. :65.00
## CUOTA_EDAD S3 P1 P2 ESCENARIO
## Min. :1.000 Min. :5.000 Min. :2.000 Min. :2.000 Min. :1.00
## 1st Qu.:2.000 1st Qu.:6.000 1st Qu.:3.000 1st Qu.:2.000 1st Qu.:1.75
## Median :2.000 Median :7.000 Median :3.000 Median :3.000 Median :2.50
## Mean :2.122 Mean :6.675 Mean :3.072 Mean :2.678 Mean :2.50
## 3rd Qu.:3.000 3rd Qu.:7.000 3rd Qu.:4.000 3rd Qu.:3.000 3rd Qu.:3.25
## Max. :3.000 Max. :7.000 Max. :4.000 Max. :4.000 Max. :4.00
## P3 P4 P5_1 P5_2 P6_1
## Min. :1.000 Min. :1.00 Min. :1.000 Min. :1.000 Min. :1.00
## 1st Qu.:1.000 1st Qu.:5.00 1st Qu.:1.000 1st Qu.:1.000 1st Qu.:5.00
## Median :1.000 Median :6.00 Median :1.000 Median :1.000 Median :5.00
## Mean :1.401 Mean :5.86 Mean :1.449 Mean :1.446 Mean :5.25
## 3rd Qu.:2.000 3rd Qu.:7.00 3rd Qu.:2.000 3rd Qu.:2.000 3rd Qu.:6.00
## Max. :2.000 Max. :7.00 Max. :2.000 Max. :2.000 Max. :7.00
## P6_2 P6_3 P7_1 P7_2
## Min. :1.000 Min. :1.000 Min. :1.000 Min. :1.000
## 1st Qu.:3.000 1st Qu.:4.000 1st Qu.:5.000 1st Qu.:4.750
## Median :4.000 Median :5.000 Median :6.000 Median :5.000
## Mean :4.322 Mean :5.306 Mean :5.806 Mean :5.286
## 3rd Qu.:5.000 3rd Qu.:7.000 3rd Qu.:7.000 3rd Qu.:6.000
## Max. :7.000 Max. :7.000 Max. :7.000 Max. :7.000
## P7_3 P7_4 P8_1 P8_2
## Min. :1.000 Min. :1.000 Min. :1.000 Min. :1.000
## 1st Qu.:4.750 1st Qu.:4.000 1st Qu.:2.000 1st Qu.:2.000
## Median :5.000 Median :5.000 Median :4.000 Median :4.000
## Mean :5.258 Mean :5.319 Mean :3.375 Mean :3.431
## 3rd Qu.:6.000 3rd Qu.:6.000 3rd Qu.:5.000 3rd Qu.:5.000
## Max. :7.000 Max. :7.000 Max. :7.000 Max. :7.000
## P8_3
## Min. :1.000
## 1st Qu.:1.750
## Median :4.000
## Mean :3.364
## 3rd Qu.:5.000
## Max. :7.000
```

### 3 RECODIFICAR LAS VARIABLES

```
df <- df %>%
  # 1. Recodificar variables de entorno y chequeos
  mutate(
    S2 = factor(S2,
                levels = c(1, 2),
                labels = c("Masculino", "Femenino")),
    CuotaEdad = factor(CUOTA_EDAD,
                       levels = c(1, 2, 3),
                       labels = c("18-30", "31-50", "51-65")),
```

```

TamPob      = factor(S3,
                      levels = 1:8,
                      labels = c("<5.000", "5.001-10.000", "10.001-25.000",
                                "25.001-50.000", "50.001-100.000",
                                "100.001-500.000", ">500.000", "Desconocido")),
Escenario   = factor(ESCAPARIO,
                      levels = 1:4,
                      labels = c("BajaConf+Auto", "AltaConf+Auto",
                                "BajaConf+Asist", "AltaConf+Asist")),
CompraBin   = factor(P3,
                      levels = c(1, 2),
                      labels = c("Tienda", "Online")),
CheckConf   = factor(P5_1,
                      levels = c(1, 2),
                      labels = c("PercibióAltaConf", "PercibióBajaConf")),
CheckServ   = factor(P5_2,
                      levels = c(1, 2),
                      labels = c("PercibióAsist", "PercibióAuto"))
) %>%
# 2. Crear variables derivadas para el análisis
mutate(
  CONFIANZA = if_else(ESCAPARIO %in% c(1, 3), 1, 2), # 1=Baja, 2=Alta
  SERVICIO  = if_else(ESCAPARIO %in% c(1, 2), 1, 2), # 1=Auto, 2=Asistido

  # Showrooming: 1 = visitó tienda y compró online, 0 = compró en tienda
  SHOWROOMING = if_else(P3 == 2, 1, 0)
) %>%
# 3. Convertir las nuevas variables en factores con etiquetas
mutate(
  CONFIANZA   = factor(CONFIANZA,
                        levels = c(1, 2),
                        labels = c("BajaConfianza", "AltaConfianza")),
  SERVICIO     = factor(SERVICIO,
                        levels = c(1, 2),
                        labels = c("Autoservicio", "Asistido")),
  SHOWROOMING  = factor(SHOWROOMING,
                        levels = c(0, 1),
                        labels = c("No", "Sí"))
)

```

## 4 LIMPIEZA DE DATOS

```

# Calcular % de NA en las escalas principales y P3_2
vars_na <- c(paste0("P6_", 1:3),
             paste0("P7_", 1:4),
             paste0("P8_", 1:3)
            )

df <- df %>%
  rowwise() %>%
  mutate(pct_na = sum(is.na(c_across(all_of(vars_na)))) / length(vars_na)) %>%
  ungroup()

```

```

# Resumen de pct_na
summary(df$pct_na)

##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##         0         0         0         0         0         0

table(cut(df$pct_na, breaks = c(-Inf, 0, .1, 1), labels = c("0%", "0-10%", ">10%")))

##
##      0% 0-10%  >10%
##      720     0     0

# Filtrar
df_step2 <- df %>% filter(pct_na <= 0.10)
cat("Casos tras filtrar >10% NA:", nrow(df_step2),
    " (se eliminaron", nrow(df) - nrow(df_step2), "casos)\n")

## Casos tras filtrar >10% NA: 720 (se eliminaron 0 casos)

# Función para imputar media por variable
imputar_media <- function(x) ifelse(is.na(x), mean(x, na.rm = TRUE), x)

df_step3 <- df_step2

for (v in vars_na) {
  mean_v <- mean(df_step3[[v]], na.rm = TRUE)
  df_step3[[v]] <- imputar_media(df_step3[[v]])
  cat("Imputada media en", v, ":", round(mean_v, 2), "\n")
}

## Imputada media en P6_1 : 5.25
## Imputada media en P6_2 : 4.32
## Imputada media en P6_3 : 5.31
## Imputada media en P7_1 : 5.81
## Imputada media en P7_2 : 5.29
## Imputada media en P7_3 : 5.26
## Imputada media en P7_4 : 5.32
## Imputada media en P8_1 : 3.38
## Imputada media en P8_2 : 3.43
## Imputada media en P8_3 : 3.36

# Marcar qué filas tienen outliers en cada escala
outlier_flag <- function(x) {
  q <- quantile(x, c(.25, .75))
  iqr <- diff(q)
  x < (q[1] - 1.5 * iqr) | x > (q[2] + 1.5 * iqr)
}

# Para cada participante, contar en cuántas escalas es outlier
df_step3 <- df_step3 %>%
  rowwise() %>%
  mutate(
    n_outliers = sum(sapply(across(all_of(vars_na)), outlier_flag))
  ) %>%
  ungroup()

```

```
table(df_step3$n_outliers)
```

```
##  
##    0  
## 720
```

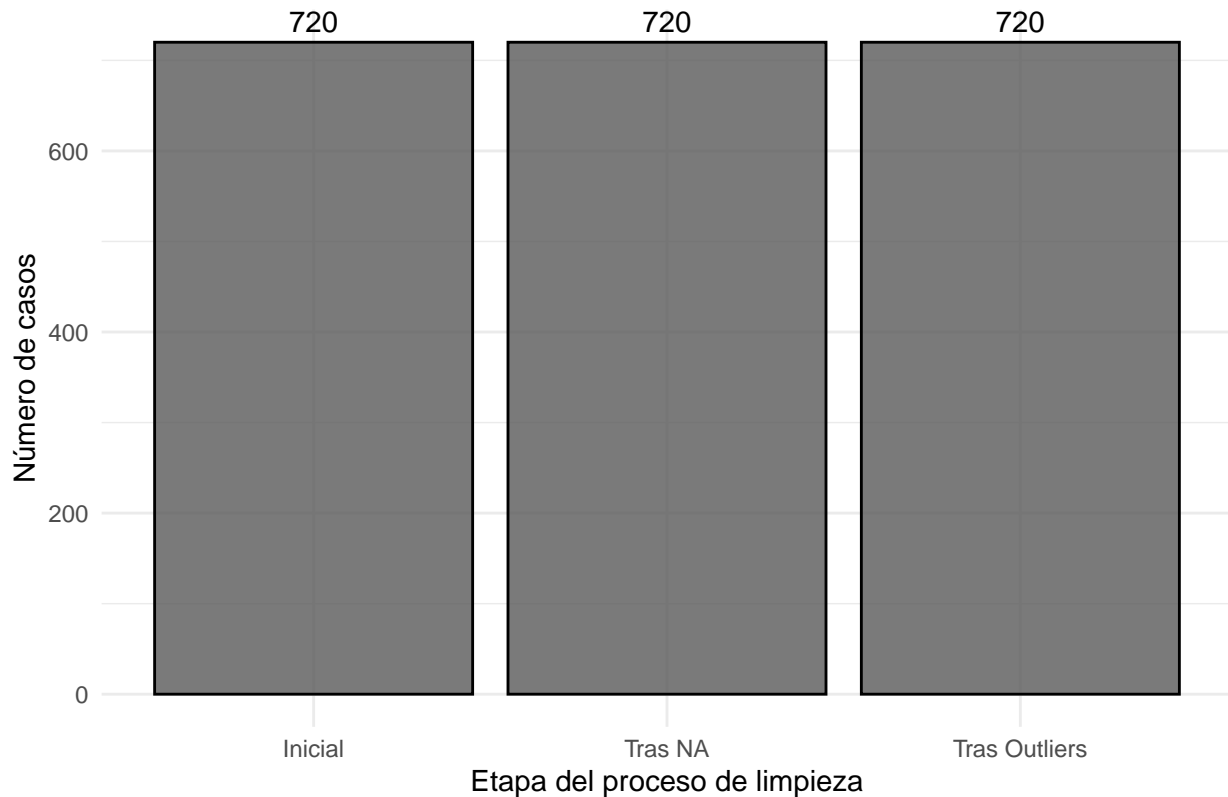
```
df_clean <- df_step3 %>% filter(n_outliers <= 2)  
cat("Casos tras eliminar >2 outliers:", nrow(df_clean),  
    " (se eliminaron", nrow(df_step3) - nrow(df_clean), "casos)\n")
```

```
## Casos tras eliminar >2 outliers: 720 (se eliminaron 0 casos)
```

```
df_summary <- tibble(  
  Etapa = c("Inicial", "Tras NA", "Tras Outliers"),  
  Casos = c(nrow(df), nrow(df_step2), nrow(df_clean))  
)
```

```
ggplot(df_summary, aes(x = Etapa, y = Casos)) +  
  geom_col(color = "black", alpha = 0.8) +  
  geom_text(aes(label = Casos), vjust = -0.5) +  
  labs(  
    x = "Etapa del proceso de limpieza",  
    y = "Número de casos",  
    title = "Evolución del tamaño de la muestra tras limpieza e imputación"  
  ) +  
  theme_minimal()
```

Evolución del tamaño de la muestra tras limpieza e imputación




```
# ESTADÍSTICOS DESCRIPTIVOS DE LA MUESTRA
```

```
df_unicos <- df %>%
  distinct(REGISTRO, .keep_all = TRUE)
```

## 4.1 Distribución variables sociodemográficas

### 4.1.1 Género

```
# GÉNERO
ggplot(df_unicos, aes(x = factor(S2, labels = c("Hombre", "Mujer")))) +
  geom_bar(color = "black", alpha = 0.8) +
  labs(x = "Género", y = "Número de participantes",
       title = "Distribución por género") +
  theme_minimal()
```



### ### Edad

```
# Estadísticos descriptivos de AGE
edad_stats <- df_unicos %>%
  summarise(
    media           = mean(AGE, na.rm = TRUE),
    mediana         = median(AGE, na.rm = TRUE),
    desviacion_tipica = sd(AGE, na.rm = TRUE),
    varianza        = var(AGE, na.rm = TRUE),
    min             = min(AGE, na.rm = TRUE),
    max             = max(AGE, na.rm = TRUE),
  )
edad_stats
```


```
## # A tibble: 1 x 6
##   media mediana desviacion_tipica varianza   min   max
##   <dbl>   <dbl>         <dbl>    <dbl> <dbl> <dbl>
## 1  42.6     43           13.2    175.   18    65
```

```
# 1. Histograma y boxplot de AGE
```

```
p_hist <- ggplot(df_unicos, aes(x = AGE)) +
  geom_histogram(binwidth = 5, color = "black", alpha = 0.8) +
  labs(x = "Edad (años)", y = "Frecuencia",
       title = "Histograma de edad") +
  theme_minimal()
```

```
p_box <- ggplot(df_unicos, aes(x = AGE)) +
  geom_boxplot(width = 0.3, color = "black", alpha = 0.8) +
  labs(x = "Edad (años)",
       title = "Boxplot de edad") +
  theme_minimal()
print(p_hist)
```


Histograma de edad



```
print(p_box)
```



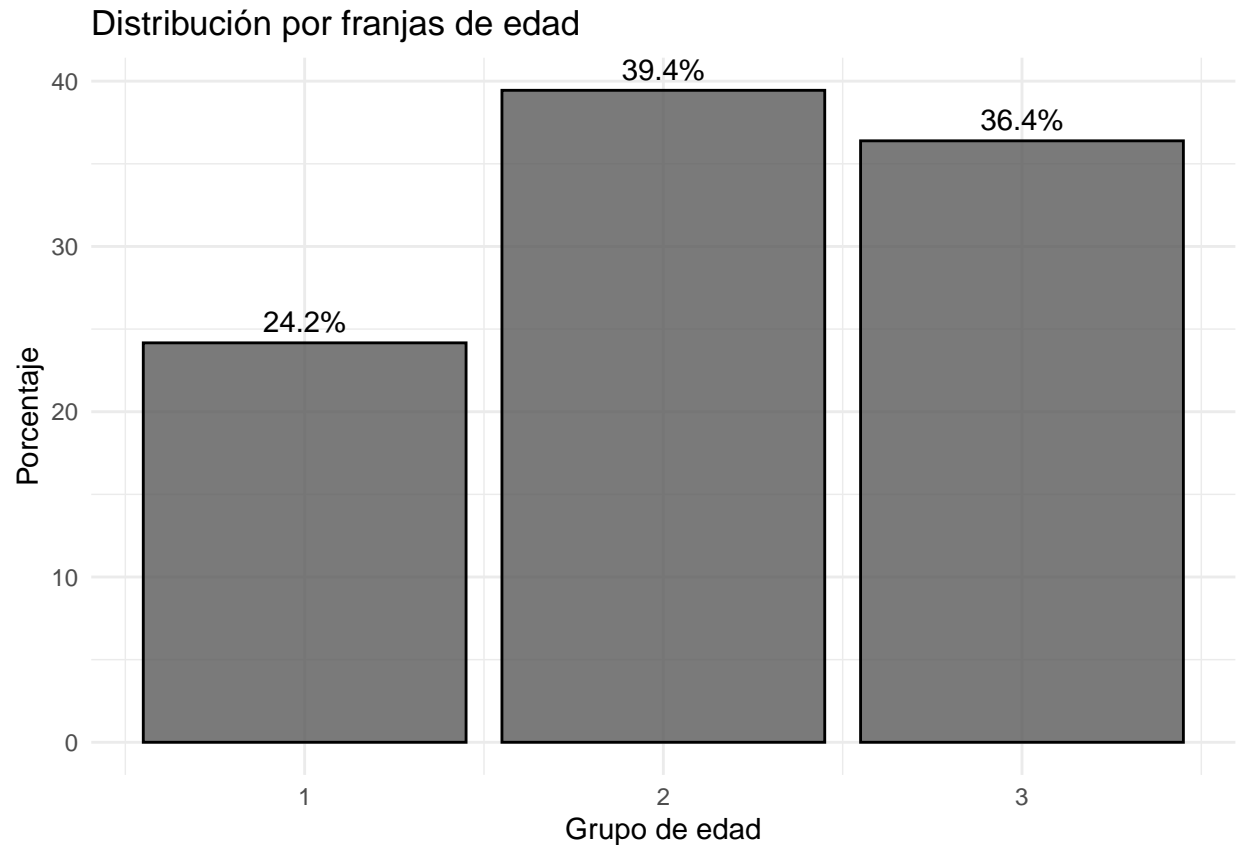
## Boxplot de edad



```
# 2. Gráfico de barras de cuotas de edad
cuota_stats <- df_unicos %>%
  count(CUOTA_EDAD) %>%
  mutate(
    pct = n / sum(n) * 100,
    grupo = case_when(
      CUOTA_EDAD == 1 ~ "18-30",
      CUOTA_EDAD == 2 ~ "31-50",
      CUOTA_EDAD == 3 ~ "51-65"
    )
  )

p_bar <- ggplot(cuota_stats, aes(x = CUOTA_EDAD, y = pct)) +
  geom_col(color = "black", alpha = 0.8) +
  geom_text(aes(label = sprintf("%.1f%%", pct)),
    vjust = -0.5) +
  labs(x = "Grupo de edad", y = "Porcentaje",
    title = "Distribución por franjas de edad") +
  theme_minimal()

print(p_bar)
```



#### 4.1.2 Tamaño municipio

*# 1. Calcular frecuencias y porcentajes para todas las categorías de S3*

```
pob_stats <- df_unicos %>%
```

```
  count(S3) %>%
```

```
  mutate(
```

```
    grupo = case_when(
```

```
      S3 == 1 ~ "Menos de 5 000",
```

```
      S3 == 2 ~ "5 001-10 000",
```

```
      S3 == 3 ~ "10 001-25 000",
```

```
      S3 == 4 ~ "25 001-50 000",
```

```
      S3 == 5 ~ "50 001-100 000",
```

```
      S3 == 6 ~ "100 001-500 000",
```

```
      S3 == 7 ~ "Más de 500 000",
```

```
      S3 == 8 ~ "Desconozco"
```

```
    ),
```

```
    pct = n / sum(n) * 100
```

```
  )
```

```
print(pob_stats)
```

```
## # A tibble: 3 x 4
```

```
##       S3      n grupo      pct
```

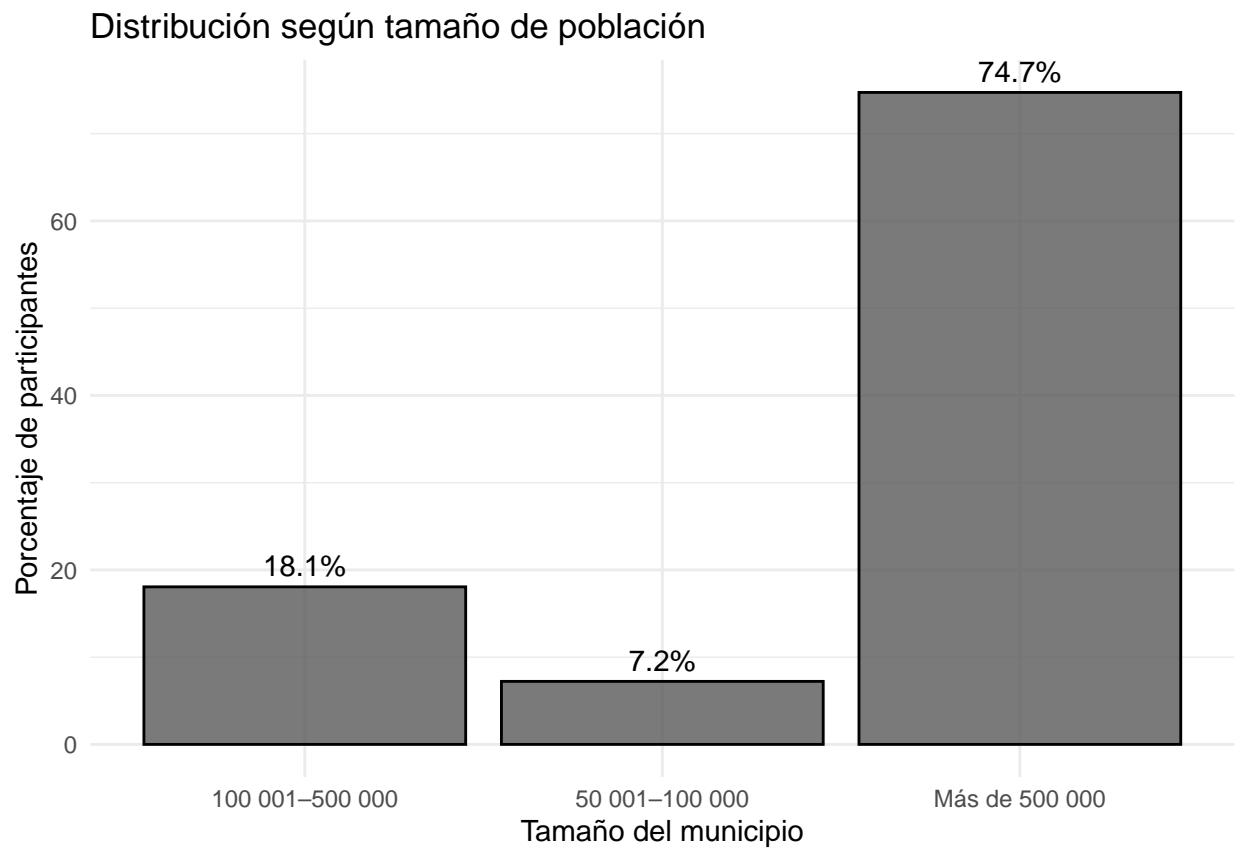
```
##   <dbl> <int> <chr>    <dbl>
```

```
## 1     5    26 50 001-100 000    7.22
```

```
## 2     6    65 100 001-500 000   18.1
```

```
## 3     7   269 Más de 500 000   74.7
```

```
# 3. Gráfico de barras para todas las categorías
ggplot(pob_stats, aes(x = grupo, y = pct)) +
  geom_col(color = "black", alpha = 0.8) +
  geom_text(aes(label = sprintf("%1.1f%%", pct)),
            vjust = -0.5)+
  labs(
    x = "Tamaño del municipio",
    y = "Porcentaje de participantes",
    title = "Distribución según tamaño de población"
  ) +
  theme_minimal()
```



## 4.2 Equilibrio Escenario


```
df_clean %>% group_by(ESCENARIO) %>% count()
```

```
## # A tibble: 4 x 2
## # Groups:   ESCENARIO [4]
##   ESCENARIO     n
##   <dbl> <int>
## 1         1    180
## 2         2    180
## 3         3    180
## 4         4    180
```

### 4.3 Tasa global Showrooming

```
# 1. Calcular frec. y % de showrooming
show_stats <- df_clean %>%
  count(SHOWROOMING) %>%
  mutate(
    pct = n / sum(n) * 100,
    etiqueta = if_else(SHOWROOMING == "Sí", "Sí showrooming", "No showrooming")
  )

# 2. Graficar
ggplot(show_stats, aes(x = etiqueta, y = pct)) +
  geom_col(color = "black", alpha = 0.8) +
  geom_text(aes(label = sprintf("%1.1f%%", pct)),
            vjust = -0.5) +
  labs(
    x = NULL,
    y = "Porcentaje de registros",
    title = "Proporción de registros con showrooming"
  ) +
  theme_minimal(base_size = 12)
```



### Distribución showrooming según variables sociodemográficas

```
# 1) calculamos N y peso de cada género
peso_genero <- df_unicos %>%
  count(S2) %>%
```

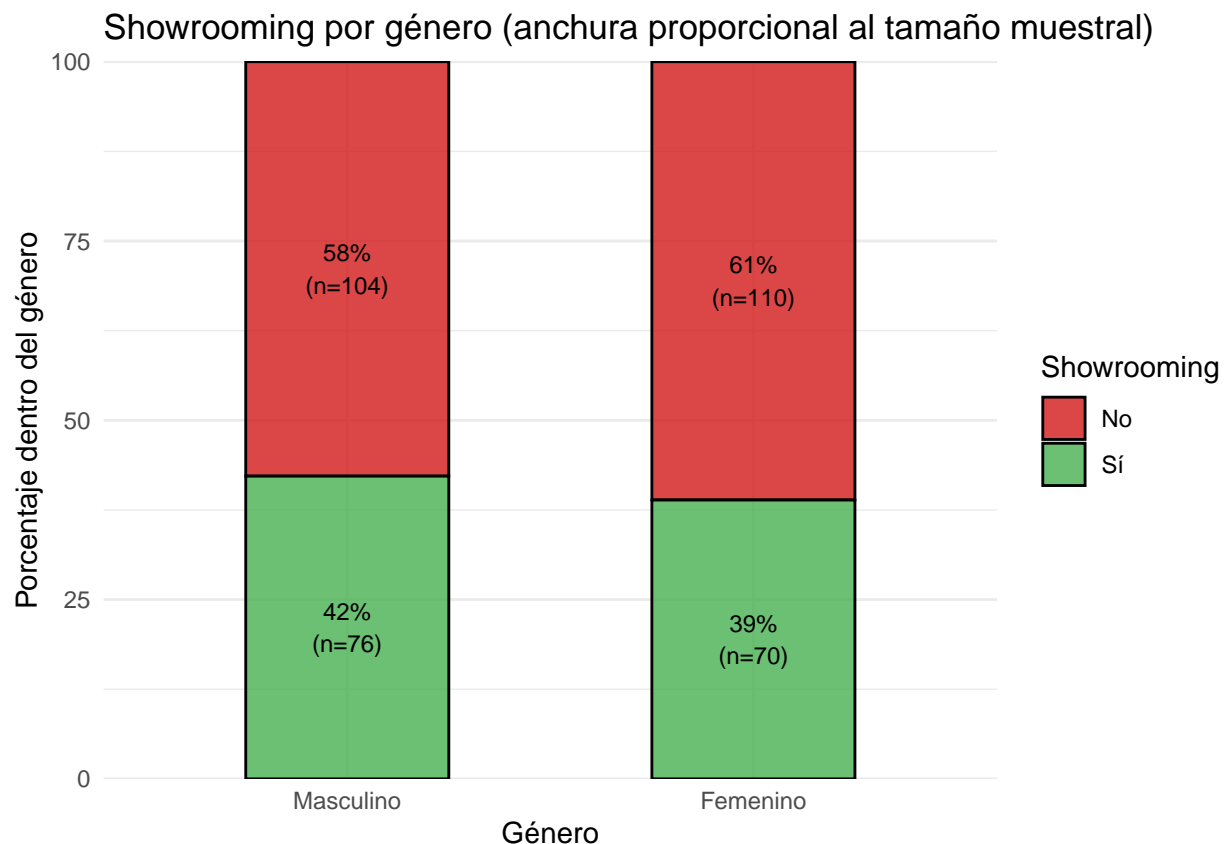
```

rename(N_gen = n) %>%
mutate(w_gen = N_gen / sum(N_gen))

# 2) calculamos % showrooming dentro de cada género
pct_genero <- df_unicos %>%
  count(S2, SHOWROOMING) %>%
  group_by(S2) %>%
  mutate(pct = n / sum(n) * 100) %>%
  ungroup() %>%
  left_join(peso_genero, by = "S2")

# 3) graficamos, usando width = w_gen en geom_col
ggplot(pct_genero, aes(x = S2, y = pct, fill = SHOWROOMING, width = w_gen)) +
  geom_col(color = "black", alpha = 0.8, position = "stack") +
  geom_text(aes(label = sprintf("%1.0f%%\n(n=%d)", pct, n)),
            position = position_stack(vjust = 0.5), size = 3) +
  scale_y_continuous(expand = c(0, 0)) +
  scale_fill_manual(values = c("No" = "#d31919", "Sí" = "#48b150")) +
  labs(
    x = "Género",
    y = "Porcentaje dentro del género",
    fill = "Showrooming",
    title = "Showrooming por género (anchura proporcional al tamaño muestral)"
  ) +
  theme_minimal()

```



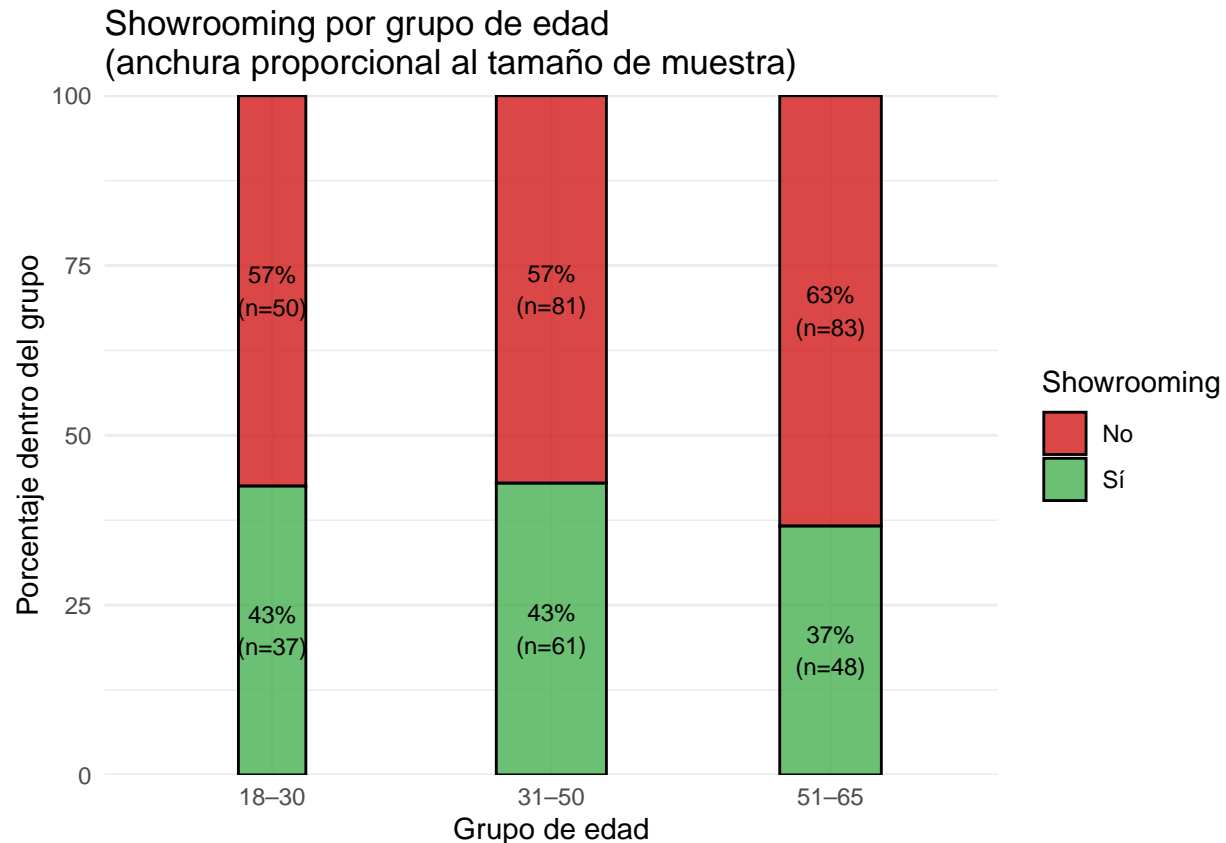
```

# Edad
# 1) Calculamos N y peso de cada grupo de edad
peso_edad <- df_unicos %>%
  count(CuotaEdad) %>%
  rename(N_edad = n) %>%
  mutate(w_edad = N_edad / sum(N_edad))

# 2) Calculamos % showrooming dentro de cada grupo de edad
pct_edad <- df_unicos %>%
  count(CuotaEdad, SHOWROOMING) %>%
  group_by(CuotaEdad) %>%
  mutate(pct = n / sum(n) * 100) %>%
  ungroup() %>%
  left_join(peso_edad, by = "CuotaEdad")

# 3) Graficamos: barras apiladas cuya anchura es proporcional al tamaño muestral
ggplot(pct_edad, aes(x = CuotaEdad, y = pct, fill = SHOWROOMING, width = w_edad)) +
  geom_col(position = "stack", color = "black", alpha = 0.8) +
  geom_text(aes(label = sprintf("%1.0f%%\n(n=%d)", pct, n)),
            position = position_stack(vjust = 0.5), size = 3) +
  scale_y_continuous(expand = c(0, 0)) +
  scale_fill_manual(values = c("No" = "#d31919", "Sí" = "#48b150")) +
  labs(
    x = "Grupo de edad",
    y = "Porcentaje dentro del grupo",
    fill = "Showrooming",
    title = "Showrooming por grupo de edad\n(anchura proporcional al tamaño de muestra)"
  ) +
  theme_minimal()

```




```
# 1) Calculamos N y peso de cada categoría de tamaño de municipio
peso_pob <- df_unicos %>%
  count(TamPob) %>%
  rename(N_pob = n) %>%
  mutate(w_pob = N_pob / sum(N_pob))

# 2) Calculamos % showrooming dentro de cada categoría
pct_pob <- df_unicos %>%
  count(TamPob, SHOWROOMING) %>%
  group_by(TamPob) %>%
  mutate(pct = n / sum(n) * 100) %>%
  ungroup() %>%
  left_join(peso_pob, by = "TamPob")

# 3) Graficamos: barras apiladas cuya anchura (width) es w_pob
ggplot(pct_pob, aes(x = TamPob, y = pct, fill = SHOWROOMING, width = w_pob)) +
  geom_col(position = "stack", color = "black", alpha = 0.8) +
  geom_text(aes(label = sprintf("%1.0f%%\n(n=%d)", pct, n),
    position = position_stack(vjust = 0.5), size = 3) +
  scale_y_continuous(expand = c(0, 0)) +
  scale_fill_manual(values = c("No" = "#d31919", "Sí" = "#48b150")) +
  labs(
    x = "Tamaño de municipio",
    y = "Porcentaje dentro de la categoría",
    fill = "Showrooming",
    title = "Showrooming por tamaño de municipio\n(anchura proporcional al tamaño muestral)"
```

```
) +  
theme_minimal()
```



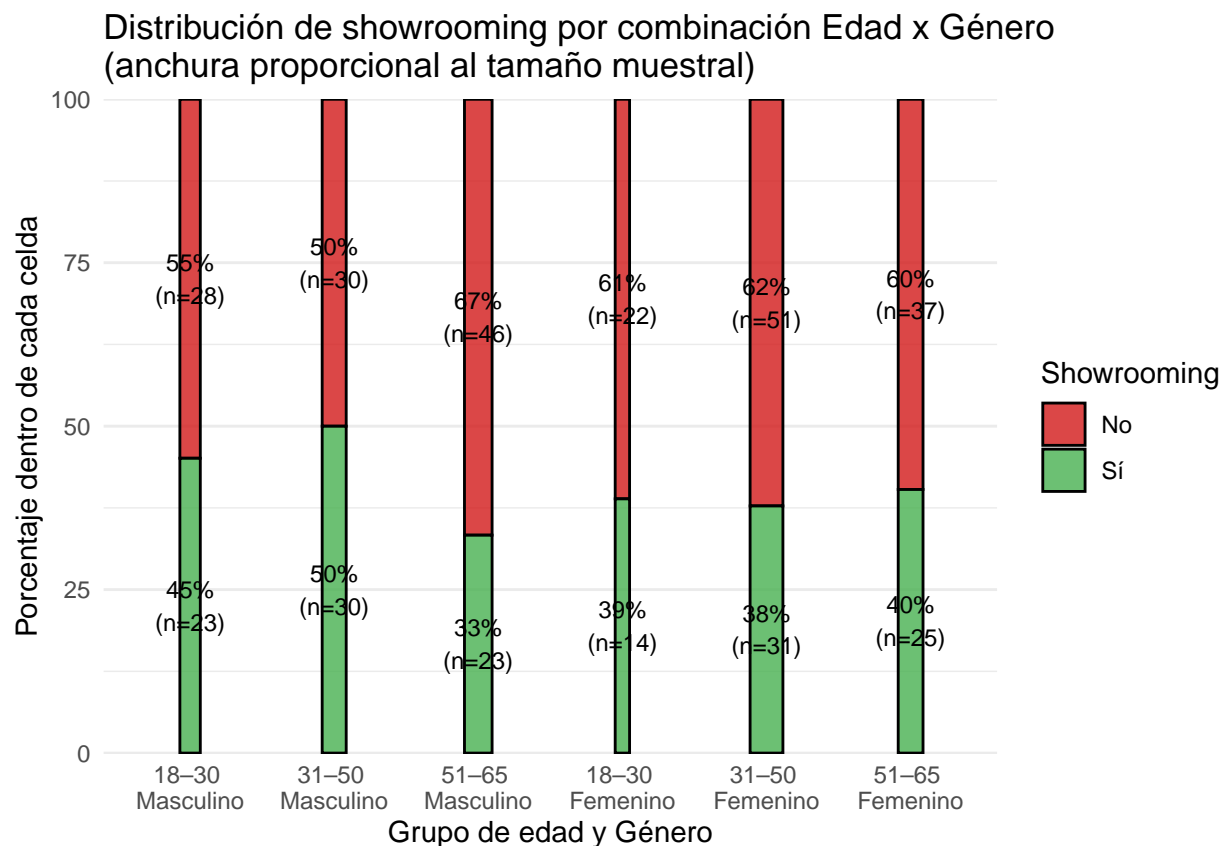
```
# 1) Peso de cada combinación Género x Edad  
peso_ge <- df_unicos %>%  
  count(S2, CuotaEdad) %>%  
  rename(N_ge = n) %>%  
  mutate(w_ge = N_ge / sum(N_ge))  
  
# 2) % showrooming dentro de cada combinación  
pct_ge <- df_unicos %>%  
  count(S2, CuotaEdad, SHOWROOMING) %>%  
  group_by(S2, CuotaEdad) %>%  
  mutate(pct = n / sum(n) * 100) %>%  
  ungroup() %>%  
  left_join(peso_ge, by = c("S2", "CuotaEdad"))  
  
# 3) Gráfico  
ggplot(pct_ge, aes(x = interaction(CuotaEdad, S2, sep = " \n"),  
  y = pct,  
  fill = SHOWROOMING,  
  width = w_ge)) +  
  geom_col(position = "stack", color = "black", alpha = 0.8) +  
  geom_text(aes(label = sprintf("%1.0f%%\n(n=%d)", pct, n)),  
    position = position_stack(vjust = 0.5), size = 3) +  
  scale_y_continuous(expand = c(0, 0)) +
```



```

scale_fill_manual(values = c("No" = "#d31919", "Sí" = "#48b150")) +
labs(
  x = "Grupo de edad y Género",
  y = "Porcentaje dentro de cada celda",
  fill = "Showrooming",
  title = "Distribución de showrooming por combinación Edad x Género\n(anchura proporcional al tamaño
) +
theme_minimal() +
theme(
  axis.text.x = element_text(hjust = 0.5),
  panel.grid.major.x = element_blank()
)

```



```

# 1) Peso de cada combinación GéneroxEdadxMunicipio
peso_tripleta <- df_clean %>%
  count(S2, CuotaEdad, TamPob) %>%
  rename(N_trip = n) %>%
  mutate(w_trip = N_trip / sum(N_trip))


# 2) % showrooming dentro de cada combinación
pct_tripleta <- df_clean %>%
  count(S2, CuotaEdad, TamPob, SHOWROOMING) %>%
  group_by(S2, CuotaEdad, TamPob) %>%
  mutate(pct = n / sum(n) * 100) %>%
  ungroup() %>%
  left_join(peso_tripleta, by = c("S2", "CuotaEdad", "TamPob"))

```

# 3) Gráfico con facet\_grid Género vs Edad

```
ggplot(pct_tripleta,
  aes(x = TamPob,
    y = pct,
    fill = SHOWROOMING,
    width = w_trip)) +
  geom_col(position = "stack", color = "black", alpha = 0.8) +
  geom_text(aes(label = sprintf("%1.0f%%\n(n=%d)", pct, n)),
    position = position_stack(vjust = 0.5),
    size = 2.5) +
  facet_grid(rows = vars(S2), cols = vars(CuotaEdad),
    scales = "free_x", space = "free_x",
    switch = "y") +
  scale_y_continuous(expand = c(0, 0)) +
  scale_fill_manual(values = c("No" = "#d31919", "Sí" = "#48b150")) +
  labs(
    x = "Tamaño de municipio",
    y = "Porcentaje dentro de la celda",
    fill = "Showrooming",
    title = "Showrooming por Género, Edad y Tamaño de municipio\n(anchura proporcional al tamaño muestr
  ) +
  theme_minimal() +
  theme(
    axis.text.x = element_text(angle = 45, hjust = 1),
    strip.placement = "outside",
    strip.background.x = element_blank(),
    strip.background.y = element_blank(),
    strip.text.x = element_text(face = "bold"),
    strip.text.y.left = element_text(face = "bold", angle = 0),
    panel.grid.major.x = element_blank()
  )
)
```

## Showrooming por Género, Edad y Tamaño de municipio (anchura proporcional al tamaño muestral)



### 4.4 Distribución Escalas Likert

```
niveles <- c(
  "Total en desacuerdo",
  "Muy en desacuerdo",
  "En desacuerdo",
  "Ni de acuerdo ni en desacuerdo",
  "De acuerdo",
  "Muy de acuerdo",
  "Total de acuerdo"
)

to_factor_block <- function(cols) {
  lapply(df_clean[, cols], function(x)
    factor(x, levels = 1:7, labels = niveles, ordered = TRUE)
  )
}

P6_fact <- as.data.frame(to_factor_block(c("P6_1", "P6_2", "P6_3")))
P7_fact <- as.data.frame(to_factor_block(c("P7_1", "P7_2", "P7_3", "P7_4")))
P8_fact <- as.data.frame(to_factor_block(c("P8_1", "P8_2", "P8_3")))


all_items <- likert(cbind(P6_fact, P7_fact, P8_fact))

plot(all_items,
```

```

group.order = c(
  "P6_1", "P6_2", "P6_3",
  "P7_1", "P7_2", "P7_3", "P7_4",
  "P8_1", "P8_2", "P8_3"
)
) +
ggtitle("Distribución respuestas: P6, P6 y P7")

```



## 5 PROPIEDADES PSICOMETRICAS

### 5.1 Realismo escenario

#### 5.1.1 Levene's Test (homogeneidad de varianzas)

```

leveneTest(P4 ~ Escenario, data = df_clean)

## Levene's Test for Homogeneity of Variance (center = median)
##      Df F value Pr(>F)
## group  3  2.437 0.06352 .
##      716
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

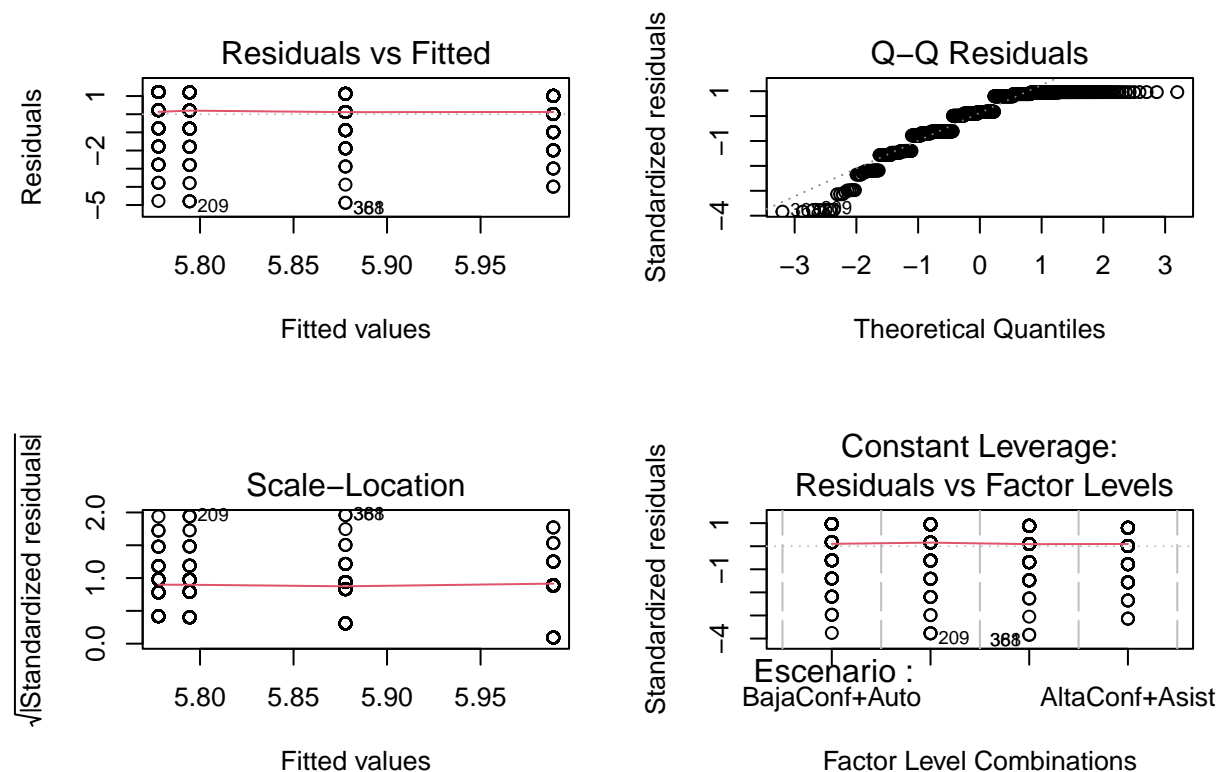
### 5.1.2 ANOVA unifactorial

```
aov_p4 <- aov(P4 ~ Escenario, data = df_clean)
summary(aov_p4)
```

```
##              Df Sum Sq Mean Sq F value Pr(>F)
## Escenario      3      5    1.679    1.033  0.377
## Residuals    716    1164    1.625
```

### 5.1.3 Diagnóstico residuos

```
par(mfrow = c(2,2))
plot(aov_p4)
```



### 5.1.4 Comparaciones post-hoc (Tukey)

```
emmeans(aov_p4, "Escenario") %>%
  contrast(method = "pairwise", adjust = "tukey")
```

```
## contrast estimate SE df t.ratio p.value
## (BajaConf+Auto) - (AltaConf+Auto) -0.0167 0.134 716 -0.124 0.9993
## (BajaConf+Auto) - (BajaConf+Asist) -0.1000 0.134 716 -0.744 0.8792
## (BajaConf+Auto) - (AltaConf+Asist) -0.2111 0.134 716 -1.571 0.3960
## (AltaConf+Auto) - (BajaConf+Asist) -0.0833 0.134 716 -0.620 0.9257
## (AltaConf+Auto) - (AltaConf+Asist) -0.1944 0.134 716 -1.447 0.4705
## (BajaConf+Asist) - (AltaConf+Asist) -0.1111 0.134 716 -0.827 0.8418
```

```
##
## P value adjustment: tukey method for comparing a family of 4 estimates
```

## 5.2 Chequeo de confianza percibida

```
# 1 Construir tabla de contingencia
tab_conf <- table(df_clean$Escenario, df_clean$P5_1,
                  dnn = c("Escenario", "Percibió confianza"))
```

```
# 2 Ver tabla observada
print(tab_conf)
```

```
##                Percibió confianza
## Escenario      1      2
## BajaConf+Auto  56 124
## AltaConf+Auto 147  33
## BajaConf+Asist 45 135
## AltaConf+Asist 149  31
```

```
# 3 Test  $\chi^2$ 
chisq_conf <- chisq.test(tab_conf, correct = FALSE)
chisq_conf
```

```
##
## Pearson's Chi-squared test
##
## data:  tab_conf
## X-squared = 214.91, df = 3, p-value < 2.2e-16
```

```
# 4 Tabla de frecuencias esperadas
chisq_conf$expected
```

```
##                Percibió confianza
## Escenario      1      2
## BajaConf+Auto 99.25 80.75
## AltaConf+Auto 99.25 80.75
## BajaConf+Asist 99.25 80.75
## AltaConf+Asist 99.25 80.75
```

```
# 5 Residuos estandarizados
round(chisq_conf$stdres, 2)
```

```
##                Percibió confianza
## Escenario      1      2
## BajaConf+Auto -7.48  7.48
## AltaConf+Auto  8.26 -8.26
## BajaConf+Asist -9.39  9.39
## AltaConf+Asist  8.61 -8.61
```

## 5.3 Chequeo de servicio percibido

```
# 1 Construir tabla de contingencia
tab_serv <- table(df_clean$Escenario, df_clean$P5_2,
                  dnn = c("Escenario", "Percibió servicio"))
```

```
# 2 Ver tabla observada
```

```
print(tab_serv)
```

```
##              Percibió servicio
## Escenario      1      2
##  BajaConf+Auto  49 131
##  AltaConf+Auto  43 137
##  BajaConf+Asist 155  25
##  AltaConf+Asist 152  28
```

```
# 3 Test X2
```

```
chisq_serv <- chisq.test(tab_serv, correct = FALSE)
```

```
chisq_serv
```

```
##
## Pearson's Chi-squared test
##
## data:  tab_serv
## X-squared = 260.36, df = 3, p-value < 2.2e-16
```

```
# 4 Tabla de frecuencias esperadas
```

```
chisq_serv$expected
```

```
##              Percibió servicio
## Escenario      1      2
##  BajaConf+Auto 99.75 80.25
##  AltaConf+Auto 99.75 80.25
##  BajaConf+Asist 99.75 80.25
##  AltaConf+Asist 99.75 80.25
```

```
# 5 Residuos estandarizados
```

```
round(chisq_serv$stdres, 2)
```

```
##              Percibió servicio
## Escenario      1      2
##  BajaConf+Auto -8.79  8.79
##  AltaConf+Auto -9.83  9.83
##  BajaConf+Asist  9.57 -9.57
##  AltaConf+Asist  9.05 -9.05
```

## 5.4 Análisis Factorial Confirmatorio y propiedades psiconometricas

### 5.4.1 Definición del modelo de medida

```
modelo_cfa <- '
# 1) Definición de los factores latentes y sus indicadores
GratInmed =~ 1*P6_1 + P6_2 + P6_3
Precio    =~ 1*P7_1 + P7_2 + P7_3 + P7_4
MalaConsc =~ 1*P8_1 + P8_2 + P8_3

# 2) Liberar las covarianzas entre los tres factores
GratInmed ~~ Precio
GratInmed ~~ MalaConsc
Precio    ~~ MalaConsc
'
```

### 5.4.2 Estimación del CFA

```
# 1) Ajuste del CFA
fit <- cfa(
  model      = modelo_cfa,
  data       = df_clean,
  std.lv     = FALSE,          # escalamos fijando cargas, no varianza latente
  estimator  = "MLM"           # ML robusto
)
```

```
# 2) Resumen con medidas de ajuste y estandarizados
```

```
summary(fit,
  fit.measures = TRUE,
  standardized = TRUE)
```

```
## lavaan 0.6-19 ended normally after 38 iterations
```

```
##
##      Estimator                      ML
##      Optimization method          NLMINB
##      Number of model parameters      23
##
##      Number of observations          720
##
## Model Test User Model:
##
##      Standard      Scaled
##      Test Statistic  201.881  146.022
##      Degrees of freedom      32      32
##      P-value (Chi-square)    0.000    0.000
##      Scaling correction factor      1.383
##      Satorra-Bentler correction
##
## Model Test Baseline Model:
##
##      Test statistic      3007.034  2378.339
##      Degrees of freedom      45      45
##      P-value              0.000    0.000
##      Scaling correction factor      1.264
##
## User Model versus Baseline Model:
##
##      Comparative Fit Index (CFI)      0.943    0.951
##      Tucker-Lewis Index (TLI)        0.919    0.931
##
##      Robust Comparative Fit Index (CFI)      0.947
##      Robust Tucker-Lewis Index (TLI)        0.925
##
## Loglikelihood and Information Criteria:
##
##      Loglikelihood user model (H0)      -11639.506  -11639.506
##      Loglikelihood unrestricted model (H1) -11538.565  -11538.565
##
##      Akaike (AIC)                23325.011  23325.011
##      Bayesian (BIC)                23430.334  23430.334
##      Sample-size adjusted Bayesian (SABIC) 23357.303  23357.303
```



```

##
## Root Mean Square Error of Approximation:
##
##   RMSEA                                0.086      0.070
##   90 Percent confidence interval - lower    0.075      0.061
##   90 Percent confidence interval - upper    0.097      0.080
##   P-value H_0: RMSEA <= 0.050              0.000      0.000
##   P-value H_0: RMSEA >= 0.080              0.812      0.056
##
##   Robust RMSEA                                0.083
##   90 Percent confidence interval - lower    0.069
##   90 Percent confidence interval - upper    0.097
##   P-value H_0: Robust RMSEA <= 0.050        0.000
##   P-value H_0: Robust RMSEA >= 0.080        0.645
##
## Standardized Root Mean Square Residual:
##
##   SRMR                                0.047      0.047
##
## Parameter Estimates:
##
##   Standard errors                        Robust.sem
##   Information                          Expected
##   Information saturated (h1) model      Structured
##
## Latent Variables:
##           Estimate  Std.Err  z-value  P(>|z|)  Std.lv  Std.all
##   GratInmed =~
##     P6_1           1.000
##     P6_2           0.975    0.079   12.402    0.000    1.037    0.645
##     P6_3           0.774    0.077   10.113    0.000    0.823    0.568
##   Precio =~
##     P7_1           1.000
##     P7_2           1.233    0.065   18.851    0.000    1.056    0.778
##     P7_3           1.250    0.084   14.858    0.000    1.071    0.745
##     P7_4           1.067    0.070   15.205    0.000    0.914    0.727
##   MalaConsc =~
##     P8_1           1.000
##     P8_2           1.051    0.044   24.141    0.000    1.533    0.862
##     P8_3           1.113    0.044   25.382    0.000    1.622    0.884
##
## Covariances:
##           Estimate  Std.Err  z-value  P(>|z|)  Std.lv  Std.all
##   GratInmed ~~
##     Precio          0.266    0.052    5.121    0.000    0.292    0.292
##     MalaConsc        0.186    0.074    2.526    0.012    0.120    0.120
##   Precio ~~
##     MalaConsc       -0.237    0.059   -3.980    0.000   -0.190   -0.190
##
## Variances:
##           Estimate  Std.Err  z-value  P(>|z|)  Std.lv  Std.all
##   .P6_1           0.584    0.095    6.170    0.000    0.584    0.341
##   .P6_2           1.510    0.142   10.628    0.000    1.510    0.584
##   .P6_3           1.418    0.105   13.459    0.000    1.418    0.677

```

```
##      .P7_1      0.640    0.056   11.444    0.000    0.640    0.466
##      .P7_2      0.728    0.079    9.262    0.000    0.728    0.395
##      .P7_3      0.918    0.112    8.190    0.000    0.918    0.445
##      .P7_4      0.744    0.062   11.932    0.000    0.744    0.471
##      .P8_1      1.014    0.121    8.403    0.000    1.014    0.323
##      .P8_2      0.812    0.114    7.099    0.000    0.812    0.257
##      .P8_3      0.738    0.107    6.933    0.000    0.738    0.219
##      GratInmed   1.131    0.123    9.167    0.000    1.000    1.000
##      Precio      0.733    0.076    9.659    0.000    1.000    1.000
##      MalaConsc   2.125    0.151   14.096    0.000    1.000    1.000
```

#### 5.4.3 Valoración de la validez y fiabilidad del instrumento de medida

```
reliability(fit)[1,]
```

##### 5.4.3.1 Fiabilidad individual: Alpha de Cronbach

```
## GratInmed      Precio MalaConsc
## 0.6991493 0.8312931 0.8914530
```

```
reliability(fit)[4,]
```

##### 5.4.3.2 Fiabilidad compuesta (CR)

```
## GratInmed      Precio MalaConsc
## 0.7132338 0.8333141 0.8926309
```

```
reliability(fit)[5,]
```

##### 5.4.3.3 Validez convergente (AVE)

```
## GratInmed      Precio MalaConsc
## 0.4507367 0.5581757 0.7348126
```

```
lavInspect(fit, what="cor.lv")^2
```

##### 5.4.3.4 Validez discriminante

```
##          GrtInm Precio MlCnsc
## GratInmed 1.000
## Precio    0.085 1.000
## MalaConsc 0.014 0.036 1.000
```

```
htmt(modelo_cfa, df_clean)
```

```
##          GrtInm Precio MlCnsc
## GratInmed 1.000
## Precio    0.280 1.000
## MalaConsc 0.122 0.190 1.000
```

## 6 ANÁLISIS EXPLORATORIO

### 6.1 Estadísticos descriptivos y matriz de correlaciones

```
# 1 Crear composites con nombres explícitos
df_clean <- df_clean %>%
  mutate(
    gratificacion = rowMeans(select(., P6_1:P6_3), na.rm = TRUE),
    orient_precio = rowMeans(select(., P7_1:P7_4), na.rm = TRUE),
    culpa = rowMeans(select(., P8_1:P8_3), na.rm = TRUE)
  )

# 2 Recodificar variables de manipulación
df_clean <- df_clean %>%
  mutate(
    confianza_bin = if_else(ESCENARIO %in% c(2,4), 1, 0),
    servicio_bin = if_else(ESCENARIO %in% c(3,4), 1, 0)
  )

# 3. Estadísticos descriptivos
est <- describe(df_clean %>%
  select(confianza_bin, servicio_bin, gratificacion, orient_precio, culpa))

# 4. Matriz de correlaciones (punto-biserial para binarios y Pearson para continuos)
# Tratamos los binarios como numéricos 0/1
vars_modelo <- c("confianza_bin", "servicio_bin",
  "gratificacion", "orient_precio", "culpa")
cor_mat <- df_clean %>%
  select(all_of(vars_modelo)) %>%
  cor(use = "pairwise.complete.obs", method = "pearson")

print(cor_mat)
```

```
##               confianza_bin servicio_bin gratificacion orient_precio
## confianza_bin    1.00000000    0.00000000    0.01926146    0.02277940
## servicio_bin     0.00000000    1.00000000   -0.02166915    0.03970123
## gratificacion    0.01926146   -0.02166915    1.00000000    0.23231746
## orient_precio    0.02277940    0.03970123    0.23231746    1.00000000
## culpa           -0.01422256    0.04949450    0.12039252   -0.16846323
##               culpa
## confianza_bin -0.01422256
## servicio_bin  0.04949450
## gratificacion 0.12039252
## orient_precio -0.16846323
## culpa        1.00000000
```

```
# 5. Significancia de correlaciones
corr.test(
  df_clean %>% select(all_of(vars_modelo)),
  use = "pairwise",
  method = "pearson",
  adjust = "none"
)
```

```
## Call:corr.test(x = df_clean %>% select(all_of(vars_modelo)), use = "pairwise",
```

```
##      method = "pearson", adjust = "none")
## Correlation matrix
##      confianza_bin servicio_bin gratificacion orient_precio culpa
## confianza_bin      1.00      0.00      0.02      0.02 -0.01
## servicio_bin      0.00      1.00     -0.02      0.04  0.05
## gratificacion      0.02     -0.02      1.00      0.23  0.12
## orient_precio      0.02      0.04      0.23      1.00 -0.17
## culpa             -0.01      0.05      0.12     -0.17  1.00
## Sample Size
## [1] 720
## Probability values (Entries above the diagonal are adjusted for multiple tests.)
##      confianza_bin servicio_bin gratificacion orient_precio culpa
## confianza_bin      0.00      1.00      0.61      0.54  0.70
## servicio_bin      1.00      0.00      0.56      0.29  0.18
## gratificacion      0.61      0.56      0.00      0.00  0.00
## orient_precio      0.54      0.29      0.00      0.00  0.00
## culpa             0.70      0.18      0.00      0.00  0.00
##
## To see confidence intervals of the correlations, print with the short=FALSE option
```


### 6.1.1 Mapa de calor y matriz de dispersión

```
# Mapa de calor
corr_long <- melt(
  cor_mat,
  varnames = c("x", "y"),
  value.name = "r"
)

# 6.2 Dibujar
ggplot(corr_long, aes(x = x, y = y, fill = r)) +
  geom_tile(color = "white") +
  scale_fill_distiller(
    palette = "RdBu",
    limit = c(-1, 1),
    name = "Correlación"
  ) +
  theme_minimal(base_size = 12) +
  theme(
    axis.text.x = element_text(angle = 45, hjust = 1),
    panel.grid = element_blank()
  ) +
  labs(
    x = NULL,
    y = NULL,
    title = "Mapa de calor de correlaciones",
    subtitle = "Variables predictoras para regresión logística"
  )
```

## Mapa de calor de correlaciones

Variables predictoras para regresión logística

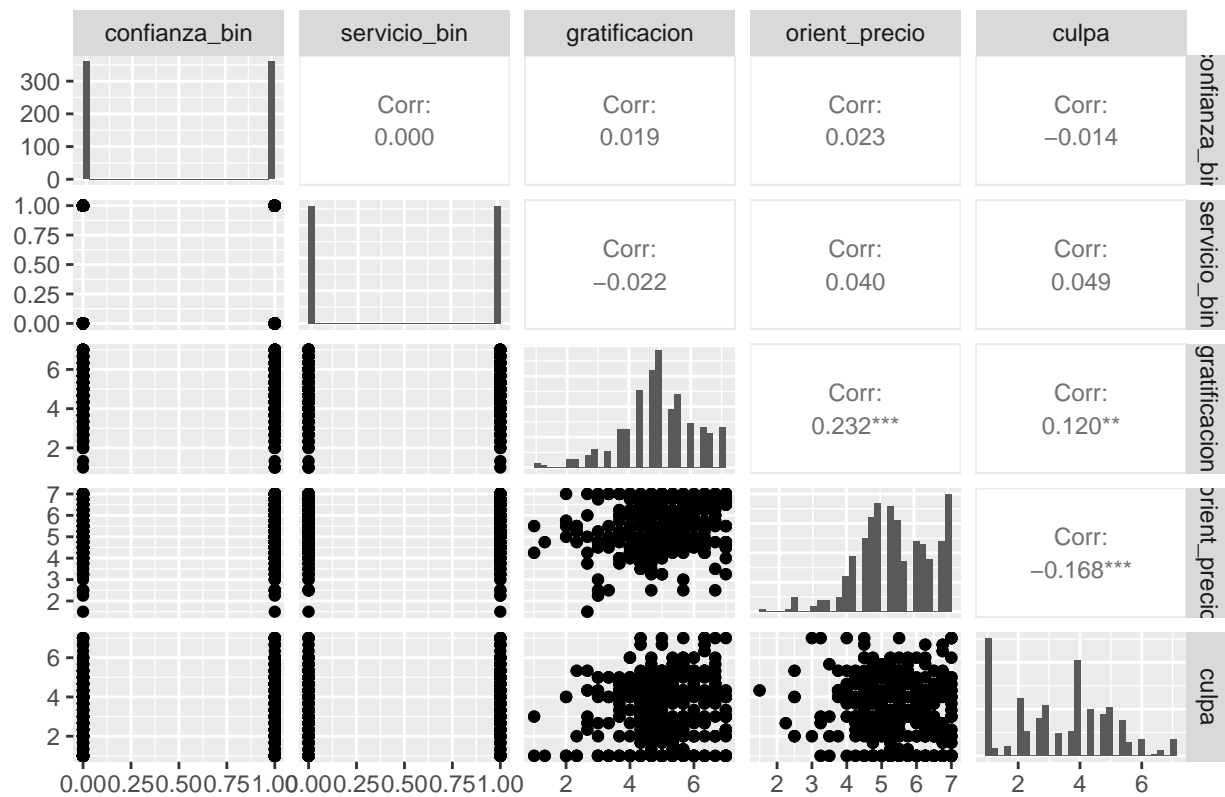


```
# Matriz de dispersión
```

```
# Matriz completa (incluyendo los binarios)
```

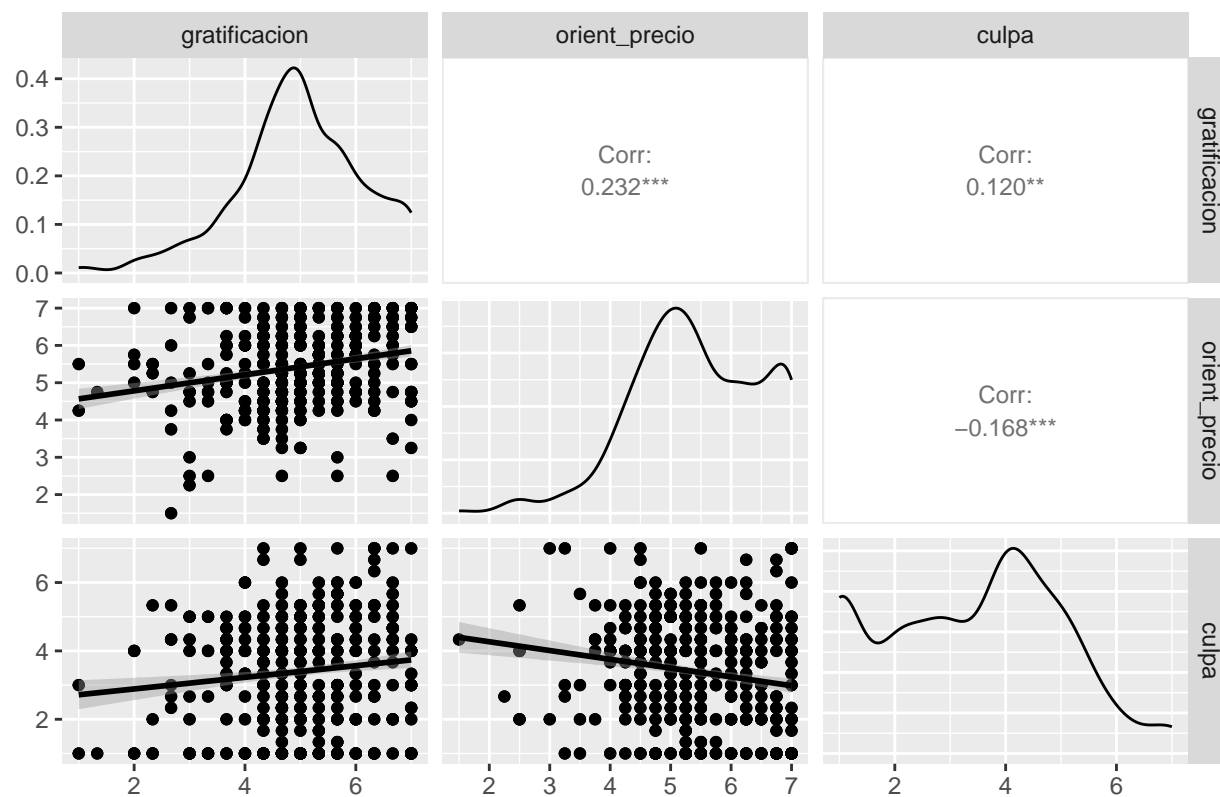
```
ggpairs(  
  df_clean[, vars_modelo],  
  upper = list(continuous = wrap("cor", size = 3)),  
  lower = list(continuous = "points"),  
  diag = list(continuous = "barDiag")  
) +  
ggtitle("Matriz de dispersión completa de predictores")
```

## Matriz de dispersión completa de predictores



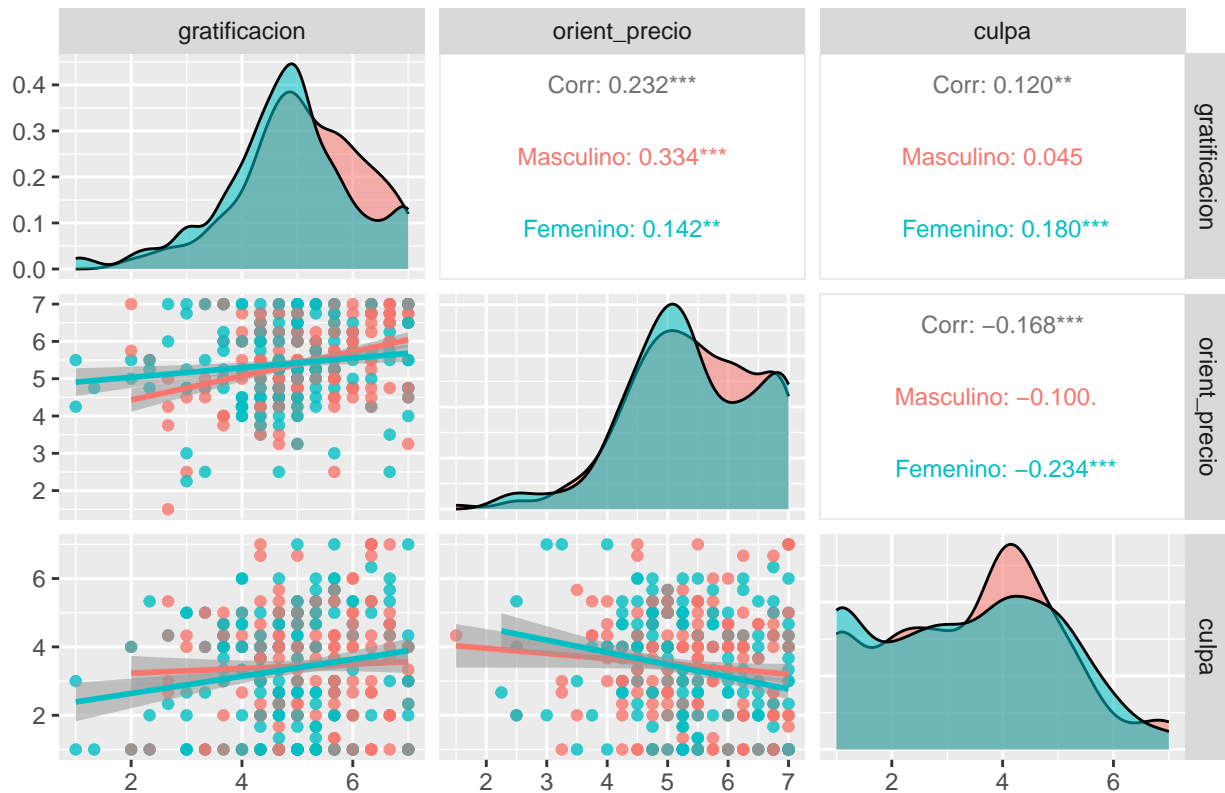
```
# Solo continuas
ggpairs(
  df_clean[, c("gratificacion", "orient_precio", "culpa")],
  upper = list(continuous = wrap("cor", size = 3)),
  lower = list(continuous = "smooth"),
  diag = list(continuous = "densityDiag")
) +
  ggtitle("Matriz de dispersión de las escalas continuas")
```

## Matriz de dispersión de las escalas continuas



```
ggpairs(
  df_clean[, c("gratificacion", "orient_precio", "culpa")],
  mapping = aes(color = df_clean$S2, alpha=0.08),
  upper   = list(continuous = wrap("cor", size = 3)),
  lower   = list(continuous = "smooth"),
  diag    = list(continuous = "densityDiag")
) +
  ggtitle("Dispersión de escalas continuas, coloreado por Sexo")
```

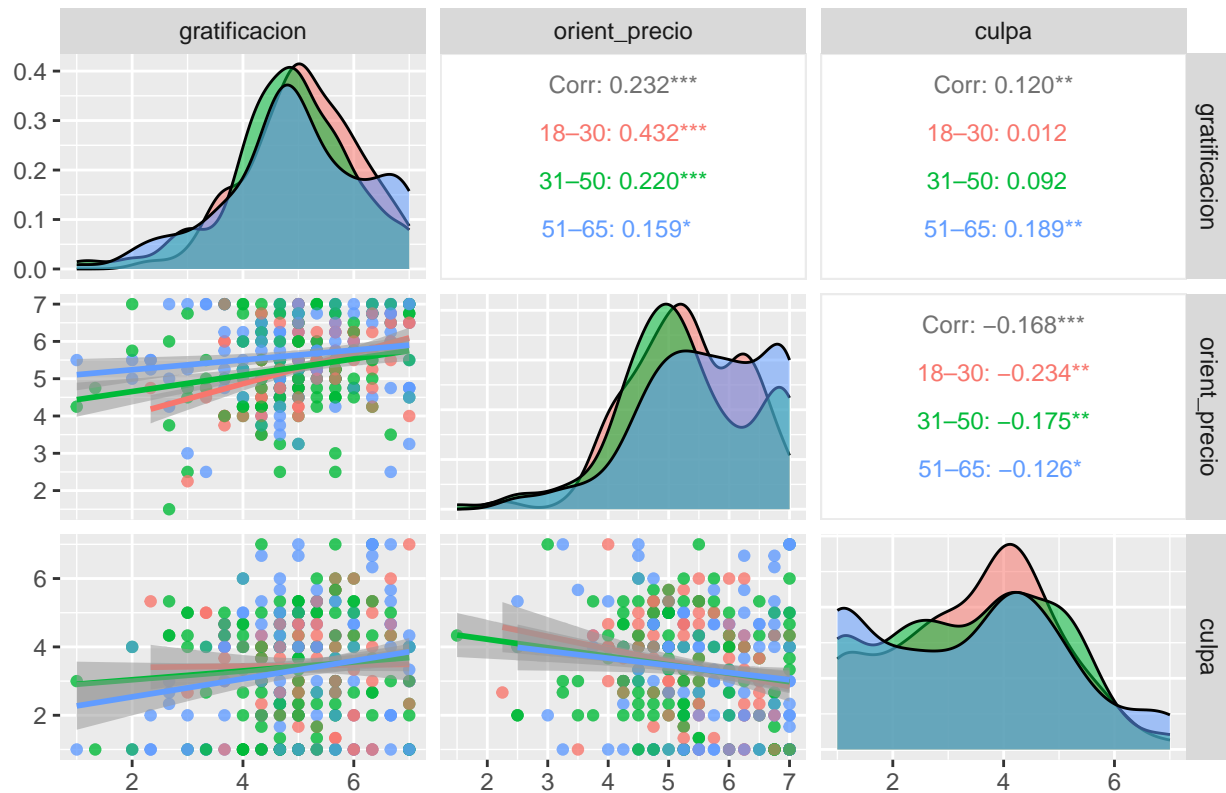
## Dispersión de escalas continuas, coloreado por Sexo



```
ggpairs(
  df_clean[, c("gratificacion", "orient_precio", "culpa")],
  mapping = aes(color = df_clean$CuotaEdad, alpha=0.08),
  upper = list(continuous = wrap("cor", size = 3)),
  lower = list(continuous = "smooth"),
  diag = list(continuous = "densityDiag")
) +
  ggtitle("Dispersión de escalas continuas, coloreado por Edad")
```

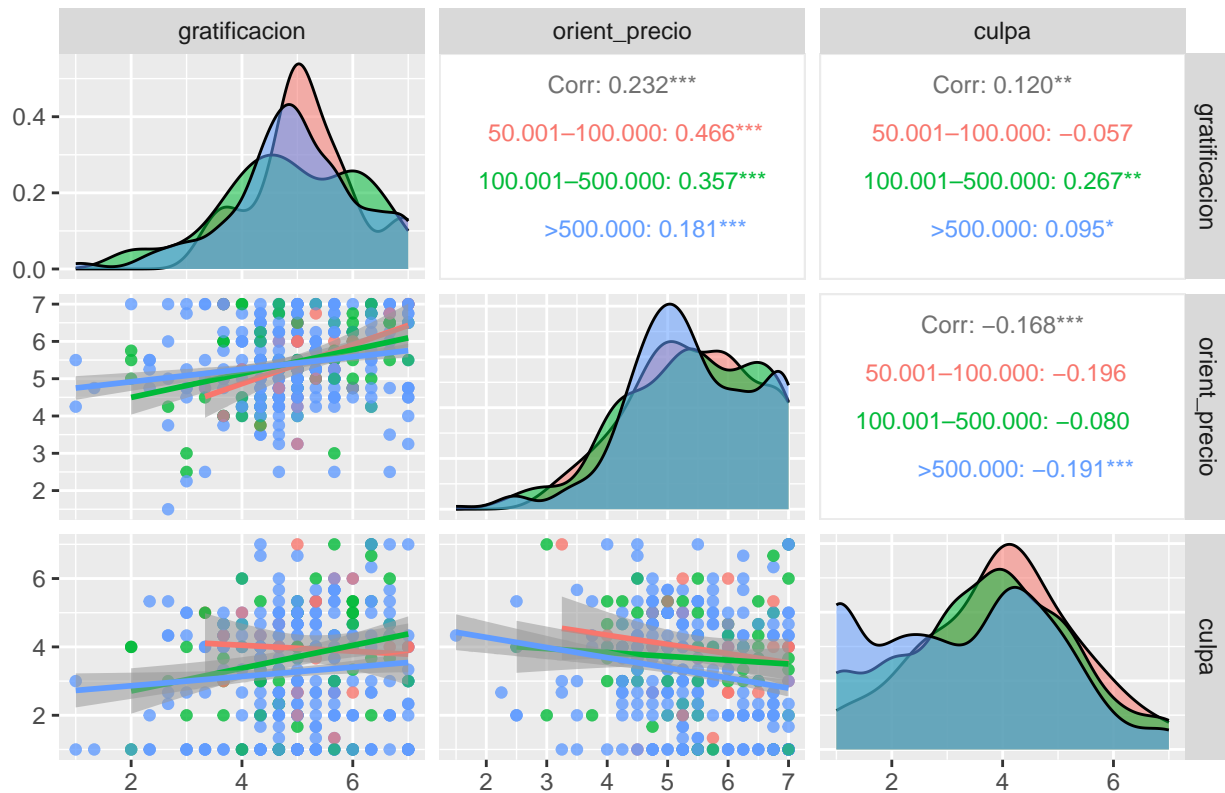


## Dispersión de escalas continuas, coloreado por Edad



```
ggpairs(
  df_clean[, c("gratificacion", "orient_precio", "culpa")],
  mapping = aes(color = df_clean$TamPob, alpha=0.08),
  upper = list(continuous = wrap("cor", size = 3)),
  lower = list(continuous = "smooth"),
  diag = list(continuous = "densityDiag")
) +
  ggtitle("Dispersión de escalas continuas, coloreado por Tamaño municipio")
```

## Dispersión de escalas continuas, coloreado por Tamaño municipio



## 7 MODELO DE REGRESIÓN LOGÍSTICA

### 7.1 Modelo inicial: sólo las cinco variables clave

```
modelo_base <- glm(
  SHOWROOMING ~ confianza_bin + servicio_bin +
    gratificacion + orient_precio + culpa,
  data = df_clean,
  family = binomial(link = "logit")
)
summary(modelo_base)
```

```
##
## Call:
## glm(formula = SHOWROOMING ~ confianza_bin + servicio_bin + gratificacion +
##   orient_precio + culpa, family = binomial(link = "logit"),
##   data = df_clean)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)  -0.14517    0.53415  -0.272  0.78580
## confianza_bin -0.21343    0.15889  -1.343  0.17918
## servicio_bin   0.22989    0.15923   1.444  0.14880
## gratificacion -0.14988    0.07167  -2.091  0.03651 *
## orient_precio  0.26111    0.07994   3.266  0.00109 **
```

```
## culpa          -0.28528    0.05150  -5.539 3.03e-08 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 969.94  on 719  degrees of freedom
## Residual deviance: 910.18  on 714  degrees of freedom
## AIC: 922.18
##
## Number of Fisher Scoring iterations: 4
```

```
AIC(modelo_base)
```

```
## [1] 922.1821
```

## 7.2 Ampliar con variables sociodemográficas

```
modelo_demo <- update(
  modelo_base,
  . ~ . + CuotaEdad + S2 + TamPob
)
summary(modelo_demo)
```

```
##
## Call:
## glm(formula = SHOWROOMING ~ confianza_bin + servicio_bin + gratificacion +
##      orient_precio + culpa + CuotaEdad + S2 + TamPob, family = binomial(link = "logit"),
##      data = df_clean)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)      0.53806    0.65303   0.824   0.4100
## confianza_bin     -0.21903    0.16025  -1.367   0.1717
## servicio_bin       0.21392    0.16032   1.334   0.1821
## gratificacion     -0.18051    0.07367  -2.450   0.0143 *
## orient_precio      0.29854    0.08257   3.616   0.0003 ***
## culpa             -0.29494    0.05279  -5.588 2.3e-08 ***
## CuotaEdad31-50     -0.14938    0.20555  -0.727   0.4674
## CuotaEdad51-65     -0.49149    0.21224  -2.316   0.0206 *
## S2Femenino         -0.20363    0.16363  -1.244   0.2133
## TamPob100.001-500.000 -0.49700    0.34886  -1.425   0.1543
## TamPob>500.000     -0.36262    0.30676  -1.182   0.2372
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 969.94  on 719  degrees of freedom
## Residual deviance: 900.64  on 709  degrees of freedom
## AIC: 922.64
##
## Number of Fisher Scoring iterations: 4
```

```
AIC(modelo_demo)

## [1] 922.644

anova(modelo_base, modelo_demo, test = "Chisq")

## Analysis of Deviance Table
##
## Model 1: SHOWROOMING ~ confianza_bin + servicio_bin + gratificacion +
##   orient_precio + culpa
## Model 2: SHOWROOMING ~ confianza_bin + servicio_bin + gratificacion +
##   orient_precio + culpa + CuotaEdad + S2 + TamPob
##   Resid. Df Resid. Dev Df Deviance Pr(>Chi)
## 1      714      910.18
## 2      709      900.64  5    9.5382  0.08943 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

### 7.3 Probar interacciones entre variables clave y demográficas

```
# - orient_precio x CuotaEdad
# - gratificacion x TamPob
# - orient_precio x S2

mod_int_op_age <- update(modelo_demo, . ~ . + orient_precio:CuotaEdad)
mod_int_gra_mun <- update(modelo_demo, . ~ . + gratificacion:TamPob)
mod_int_op_sex <- update(modelo_demo, . ~ . + orient_precio:S2)

# Comparar AIC y pruebas Chi-cuadrado
modelos_demo_int <- list(
  demo      = modelo_demo,
  op_x_age  = mod_int_op_age,
  gra_x_mun = mod_int_gra_mun,
  op_x_sex  = mod_int_op_sex
)
sapply(modelos_demo_int, AIC)

##      demo  op_x_age gra_x_mun  op_x_sex
## 922.6440  913.0752  916.0611  917.6910

anova(modelo_demo, mod_int_op_age, test = "Chisq")

## Analysis of Deviance Table
##
## Model 1: SHOWROOMING ~ confianza_bin + servicio_bin + gratificacion +
##   orient_precio + culpa + CuotaEdad + S2 + TamPob
## Model 2: SHOWROOMING ~ confianza_bin + servicio_bin + gratificacion +
##   orient_precio + culpa + CuotaEdad + S2 + TamPob + orient_precio:CuotaEdad
##   Resid. Df Resid. Dev Df Deviance Pr(>Chi)
## 1      709      900.64
## 2      707      887.08  2    13.569 0.001131 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
anova(modelo_demo, mod_int_gra_mun, test = "Chisq")
```

```
## Analysis of Deviance Table
##
## Model 1: SHOWROOMING ~ confianza_bin + servicio_bin + gratificacion +
##   orient_precio + culpa + CuotaEdad + S2 + TamPob
## Model 2: SHOWROOMING ~ confianza_bin + servicio_bin + gratificacion +
##   orient_precio + culpa + CuotaEdad + S2 + TamPob + gratificacion:TamPob
##   Resid. Df Resid. Dev Df Deviance Pr(>Chi)
## 1          709      900.64
## 2          707      890.06  2    10.583 0.005035 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
anova(modelo_demo, mod_int_op_sex, test = "Chisq")
```

```
## Analysis of Deviance Table
##
## Model 1: SHOWROOMING ~ confianza_bin + servicio_bin + gratificacion +
##   orient_precio + culpa + CuotaEdad + S2 + TamPob
## Model 2: SHOWROOMING ~ confianza_bin + servicio_bin + gratificacion +
##   orient_precio + culpa + CuotaEdad + S2 + TamPob + orient_precio:S2
##   Resid. Df Resid. Dev Df Deviance Pr(>Chi)
## 1          709      900.64
## 2          708      893.69  1     6.9529 0.008368 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

## 7.4 Probar interacciones entre variables clave

```
# - confianza_bin x culpa
# - servicio_bin x orient_precio
# - servicio_bin x gratificacion
# - gratificacion x orient_precio
# - orient_precio x culpa
mod_int_conf_culp <- update(modelo_demo, . ~ . + confianza_bin:culpa)
mod_int_serv_prec <- update(modelo_demo, . ~ . + servicio_bin:orient_precio)
mod_int_serv_gra <- update(modelo_demo, . ~ . + servicio_bin:gratificacion)
mod_int_gra_prec <- update(modelo_demo, . ~ . + gratificacion:orient_precio)
mod_int_prec_culp <- update(modelo_demo, . ~ . + orient_precio:culpa)

# Comparar AIC y Chi-cuadrado
modelos_key_int <- list(
  demo      = modelo_demo,
  conf_x_culp = mod_int_conf_culp,
  serv_x_prec = mod_int_serv_prec,
  serv_x_gra  = mod_int_serv_gra,
  gra_x_prec  = mod_int_gra_prec,
  prec_x_culp = mod_int_prec_culp
)
sapply(modelos_key_int, AIC)
```

```
##      demo conf_x_culp serv_x_prec serv_x_gra gra_x_prec prec_x_culp
## 922.6440  923.2155   924.2523   924.2083   924.5149   922.3084
```

```
anova(modelo_demo, mod_int_conf_culp, test = "Chisq")
```

```
## Analysis of Deviance Table
```

```
##
```

```
## Model 1: SHOWROOMING ~ confianza_bin + servicio_bin + gratificacion +
```

```
## orient_precio + culpa + CuotaEdad + S2 + TamPob
```

```
## Model 2: SHOWROOMING ~ confianza_bin + servicio_bin + gratificacion +
```

```
## orient_precio + culpa + CuotaEdad + S2 + TamPob + confianza_bin:culpa
```

```
## Resid. Df Resid. Dev Df Deviance Pr(>Chi)
```

```
## 1 709 900.64
```

```
## 2 708 899.22 1 1.4284 0.232
```

```
anova(modelo_demo, mod_int_serv_prec, test = "Chisq")
```

```
## Analysis of Deviance Table
```

```
##
```

```
## Model 1: SHOWROOMING ~ confianza_bin + servicio_bin + gratificacion +
```

```
## orient_precio + culpa + CuotaEdad + S2 + TamPob
```

```
## Model 2: SHOWROOMING ~ confianza_bin + servicio_bin + gratificacion +
```

```
## orient_precio + culpa + CuotaEdad + S2 + TamPob + servicio_bin:orient_precio
```

```
## Resid. Df Resid. Dev Df Deviance Pr(>Chi)
```

```
## 1 709 900.64
```

```
## 2 708 900.25 1 0.39162 0.5314
```

```
anova(modelo_demo, mod_int_serv_gra, test = "Chisq")
```

```
## Analysis of Deviance Table
```

```
##
```

```
## Model 1: SHOWROOMING ~ confianza_bin + servicio_bin + gratificacion +
```

```
## orient_precio + culpa + CuotaEdad + S2 + TamPob
```

```
## Model 2: SHOWROOMING ~ confianza_bin + servicio_bin + gratificacion +
```

```
## orient_precio + culpa + CuotaEdad + S2 + TamPob + servicio_bin:gratificacion
```

```
## Resid. Df Resid. Dev Df Deviance Pr(>Chi)
```

```
## 1 709 900.64
```

```
## 2 708 900.21 1 0.43568 0.5092
```

```
anova(modelo_demo, mod_int_gra_prec, test = "Chisq")
```

```
## Analysis of Deviance Table
```

```
##
```

```
## Model 1: SHOWROOMING ~ confianza_bin + servicio_bin + gratificacion +
```

```
## orient_precio + culpa + CuotaEdad + S2 + TamPob
```

```
## Model 2: SHOWROOMING ~ confianza_bin + servicio_bin + gratificacion +
```

```
## orient_precio + culpa + CuotaEdad + S2 + TamPob + gratificacion:orient_precio
```

```
## Resid. Df Resid. Dev Df Deviance Pr(>Chi)
```

```
## 1 709 900.64
```

```
## 2 708 900.51 1 0.12902 0.7195
```

```
anova(modelo_demo, mod_int_prec_culp, test = "Chisq")
```

```
## Analysis of Deviance Table
```

```
##
```

```
## Model 1: SHOWROOMING ~ confianza_bin + servicio_bin + gratificacion +
```

```
## orient_precio + culpa + CuotaEdad + S2 + TamPob
```

```
## Model 2: SHOWROOMING ~ confianza_bin + servicio_bin + gratificacion +
```

```
## orient_precio + culpa + CuotaEdad + S2 + TamPob + orient_precio:culpa
```

```
## Resid. Df Resid. Dev Df Deviance Pr(>Chi)
```

```
## 1      709      900.64
## 2      708      898.31  1   2.3356  0.1265
```

## 7.5 Modelo Final

```
modelo_final <- glm(
  SHOWROOMING ~ confianza_bin + servicio_bin +
    gratificacion + orient_precio + culpa +
    CuotaEdad + S2 + TamPob +
    orient_precio:CuotaEdad +
    gratificacion:TamPob +
    orient_precio:S2,
  family = binomial(link="logit"),
  data = df_clean
)


summary(modelo_final)

##
## Call:
## glm(formula = SHOWROOMING ~ confianza_bin + servicio_bin + gratificacion +
##      orient_precio + culpa + CuotaEdad + S2 + TamPob + orient_precio:CuotaEdad +
##      gratificacion:TamPob + orient_precio:S2, family = binomial(link = "logit"),
##      data = df_clean)
##
## Coefficients:
##
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)      5.84220    2.17782   2.683 0.007306 **
## confianza_bin    -0.24386    0.16375  -1.489 0.136425
## servicio_bin      0.22729    0.16384   1.387 0.165363
## gratificacion    -1.06786    0.37433  -2.853 0.004334 **
## orient_precio     0.18648    0.20172   0.924 0.355252
## culpa            -0.33243    0.05459  -6.090 1.13e-09 ***
## CuotaEdad31-50   -1.16726    1.14713  -1.018 0.308893
## CuotaEdad51-65   -4.57388    1.33151  -3.435 0.000592 ***
## S2Femenino        1.95606    0.90969   2.150 0.031536 *
## TamPob100.001-500.000 -6.58705    2.09797  -3.140 0.001691 **
## TamPob>500.000   -4.80944    1.97453  -2.436 0.014861 *
## orient_precio:CuotaEdad31-50  0.20024    0.21300   0.940 0.347167
## orient_precio:CuotaEdad51-65  0.73291    0.23651   3.099 0.001943 **
## gratificacion:TamPob100.001-500.000 1.18775    0.40516   2.932 0.003373 **
## gratificacion:TamPob>500.000  0.85111    0.38116   2.233 0.025553 *
## orient_precio:S2Femenino    -0.40258    0.16410  -2.453 0.014159 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 969.94  on 719  degrees of freedom
## Residual deviance: 870.77  on 704  degrees of freedom
## AIC: 902.77
##
## Number of Fisher Scoring iterations: 4
```

## 8 BONDAD DEL AJUSTE DEL MODELO FINAL

```
# 1) Obtener probabilidades y vector 0/1
df_clean$prob_final <- predict(modelo_final, type = "response")
df_clean$show_bin_num <- ifelse(df_clean$SHOWROOMING == "Si", 1, 0)

# 2) Curva ROC y AUC
library(pROC)
roc_obj <- roc(
  response = df_clean$show_bin_num,
  predictor = df_clean$prob_final
)
plot(roc_obj, col = "blue",
     lwd = 2,
     main = paste0(
       "Curva ROC del modelo final (AUC = ",
       round(auc(roc_obj), 3),
       ")"
     )
  )
)
```



```
auc_val <- auc(roc_obj)
cat("AUC =", round(auc_val, 4), "\n")
```

```
## AUC = 0.7079
```



```
# 3) Hosmer-Lemeshow goodness-of-fit
hl <- hoslem.test(
  x = df_clean$show_bin_num,
  y = df_clean$prob_final,
  g = 10
)
print(hl)
```

```
##
## Hosmer and Lemeshow goodness of fit (GOF) test
##
## data: df_clean$show_bin_num, df_clean$prob_final
## X-squared = 10.73, df = 8, p-value = 0.2175
```

```
# 4) Matriz de confusión
# Definir clase predicha con umbral 0.5
df_clean$pred_class <- factor(
  ifelse(df_clean$prob_final >= 0.5, "Sí", "No"),
  levels = c("No", "Sí")
)
CrossTable(
  x = df_clean$show_bin_num,
  y = df_clean$pred_class,
  prop.chisq= FALSE,
  prop.t = FALSE,
  prop.r = FALSE,
  dnn = c("Actual", "Predicho")
)
```

```
##
##
## Cell Contents
## |-----|
## | N |
## | N / Col Total |
## |-----|
##
##
## Total Observations in Table: 720
##
##
## | Predicho
## Actual | No | Sí | Row Total |
## -----|-----|-----|-----|
## 0 | 357 | 74 | 431 |
## | 0.692 | 0.363 | |
## -----|-----|-----|-----|
## 1 | 159 | 130 | 289 |
## | 0.308 | 0.637 | |
## -----|-----|-----|-----|
## Column Total | 516 | 204 | 720 |
## | 0.717 | 0.283 | |
## -----|-----|-----|-----|
##
```

```
##
# 5) Métricas (accuracy, recall, precision, F1)
cm <- table(
  Actual = df_clean$show_bin_num,
  Predicho = ifelse(df_clean$pred_class=="Sí", 1, 0)
)
TN <- cm["0","0"]; FP <- cm["0","1"]
FN <- cm["1","0"]; TP <- cm["1","1"]

accuracy <- (TP + TN) / sum(cm)
sensitivity <- TP / (TP + FN)
specificity <- TN / (TN + FP)
precision <- TP / (TP + FP)
f1_score <- 2 * precision * sensitivity / (precision + sensitivity)

metrics <- data.frame(
  Metric = c("Accuracy", "Sensitivity", "Specificity", "Precision", "F1 Score"),
  Value = c(accuracy, sensitivity, specificity, precision, f1_score)
)
print(metrics)

##      Metric      Value
## 1 Accuracy 0.6763889
## 2 Sensitivity 0.4498270
## 3 Specificity 0.8283063
## 4 Precision 0.6372549
## 5 F1 Score 0.5273834
```

## 9 INTERPRETACIÓN DE RESULTADOS

### 9.1 Global

```
# 1) Lista de continuas
vars_cont <- c("gratificacion", "orient_precio", "culpa")

# 2) Probabilidades base
p_base <- predict(modelo_final, type = "response")

# 3) Para cada variable, subimos en +1 y computamos p2
ame_cont <- sapply(vars_cont, function(var){
  newdata <- df_clean
  newdata[[var]] <- newdata[[var]] + 1
  p2 <- predict(modelo_final, newdata = newdata, type = "response")
  mean(p2 - p_base)
})

ame_cont

## gratificacion orient_precio      culpa
## -0.04322129  0.06679170 -0.06744264

vars_bin <- c("confianza_bin", "servicio_bin")

ame_bin <- sapply(vars_bin, function(var){
```

```

new1 <- df_clean; new1[[var]] <- 1
new0 <- df_clean; new0[[var]] <- 0
p1 <- predict(modelo_final, newdata = new1, type = "response")
p0 <- predict(modelo_final, newdata = new0, type = "response")
mean(p1 - p0)
})

```

ame\_bin

```

## confianza_bin  servicio_bin
##   -0.05104284   0.04760867

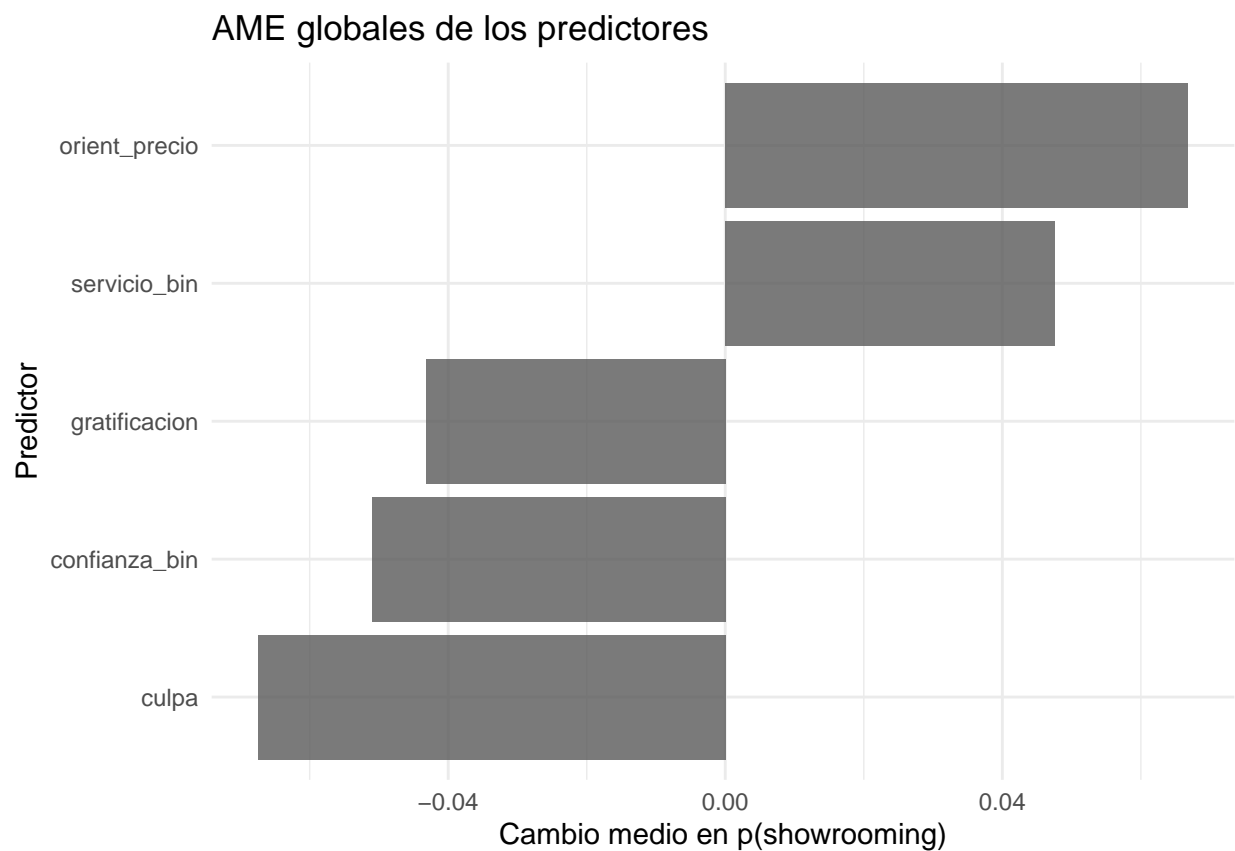
```

```

df_global <- tibble(
  predictor = c(names(ame_cont), names(ame_bin)),
  ame       = c(ame_cont, ame_bin)
)

ggplot(df_global, aes(x = reorder(predictor, ame), y = ame)) +
  geom_col(alpha = 0.8) +
  coord_flip() +
  labs(
    title = "AME globales de los predictores",
    x      = "Predictor",
    y      = "Cambio medio en p(showrooming)"
  ) +
  theme_minimal()

```



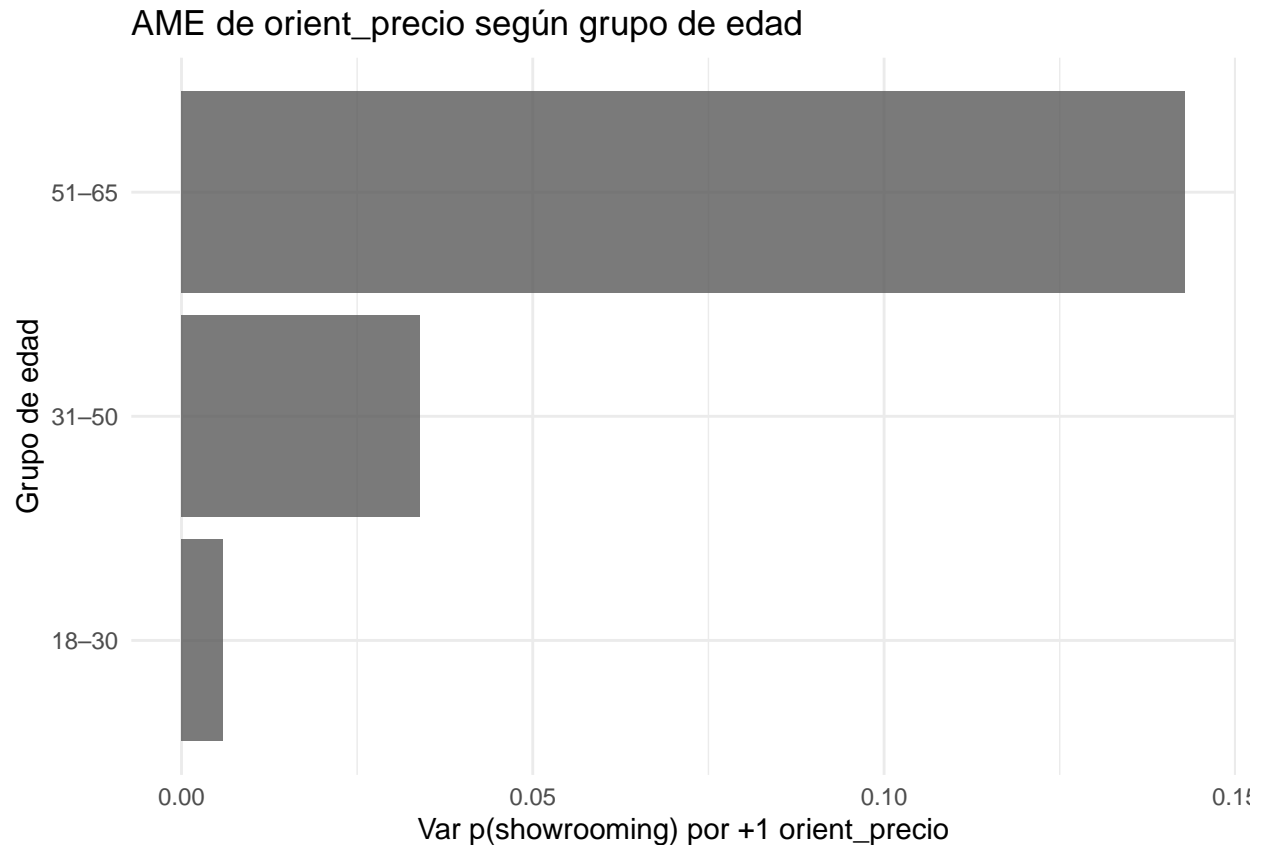
## 9.2 Orientación al precio x Grupo de edad

```
niv_edad <- levels(df_clean$CuotaEdad)
ame_op_by_age <- sapply(niv_edad, function(lv){
  sub <- df_clean; sub <- sub[sub$CuotaEdad == lv, ]
  p0 <- predict(modelo_final, newdata = sub, type = "response")
  sub2 <- sub; sub2$orient_precio <- sub2$orient_precio + 1
  p1 <- predict(modelo_final, newdata = sub2, type = "response")
  mean(p1 - p0)
})
ame_op_by_age
```

```
##          18-30          31-50          51-65
## 0.005863655 0.033944510 0.142860708
```

```
# Orient_precio x Edad
df_op_age <- tibble(
  CuotaEdad = niv_edad,
  ame       = ame_op_by_age
)

ggplot(df_op_age, aes(x = CuotaEdad, y = ame)) +
  geom_col(alpha = 0.8) +
  coord_flip() +
  labs(
    title = "AME de orient_precio según grupo de edad",
    x      = "Grupo de edad",
    y      = "Var p(showrooming) por +1 orient_precio"
  ) +
  theme_minimal()
```



### 9.3 Gratificación x Tamaño de municipio

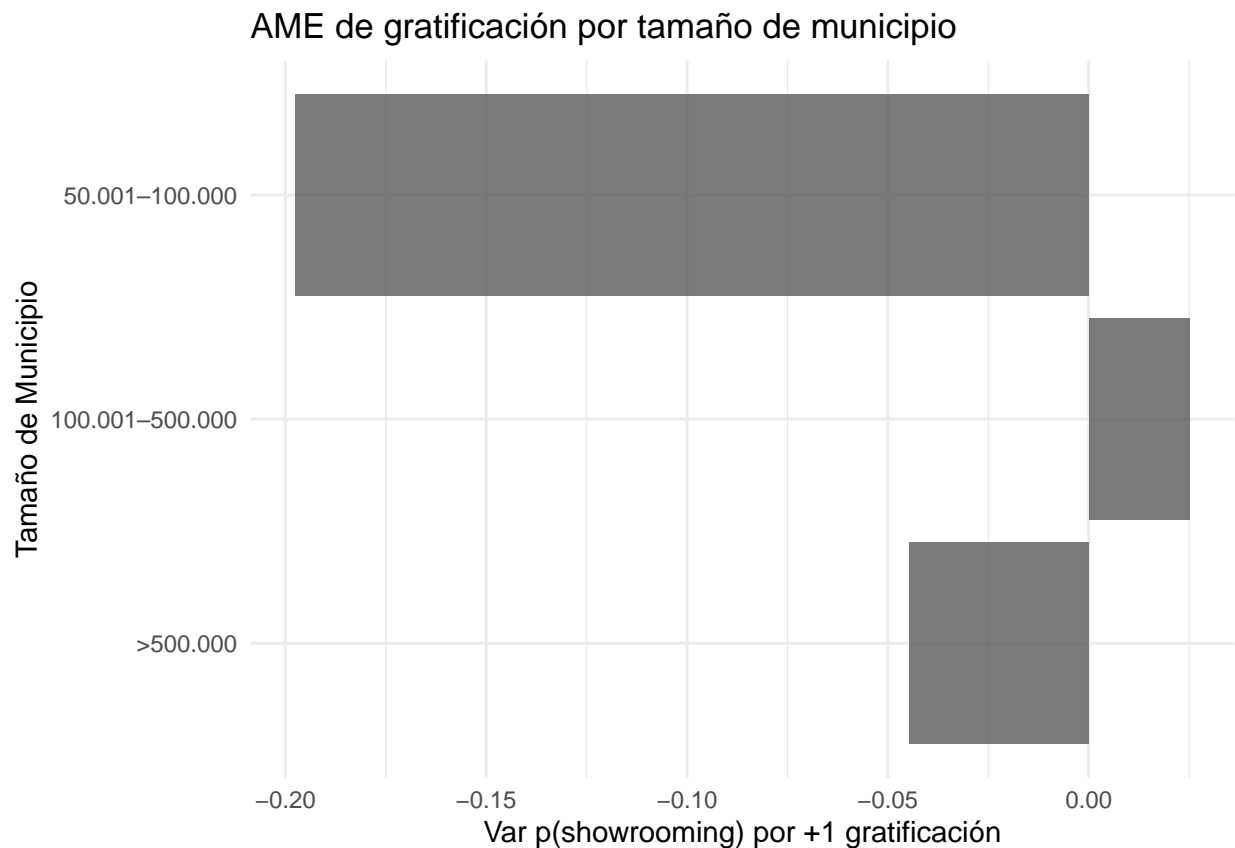
```
mun_counts <- table(df_clean$TamPob)
niveles_presentes <- names(mun_counts)[mun_counts > 0]
ame_gr_by_mun <- sapply(niveles_presentes, function(lv) {
  sub0 <- df_clean[df_clean$TamPob == lv, ]
  # Probabilidad base
  p0 <- predict(modelo_final, newdata = sub0, type = "response")
  # Subimos gratificación en +1 y predecimos de nuevo
  sub1 <- sub0
  sub1$gratificacion <- sub1$gratificacion + 1
  p1 <- predict(modelo_final, newdata = sub1, type = "response")
  # AME para ese nivel
  mean(p1 - p0)
})
```

ame\_gr\_by\_mun

```
## 50.001-100.000 100.001-500.000 >500.000
## -0.19758349 0.02511274 -0.04481346
```

```
df_gr_mun <- tibble(
  TamPob = niveles_presentes,
  ame = ame_gr_by_mun
)
```

```
ggplot(df_gr_mun, aes(x = TamPob, y = ame)) +
  geom_col(alpha = 0.8) +
  coord_flip() +
  labs(
    title = "AME de gratificación por tamaño de municipio",
    x = "Tamaño de Municipio",
    y = "Var p(showrooming) por +1 gratificación"
  ) +
  theme_minimal()
```



## Orientación al precio x Sexo

```
niv_sex <- levels(df_clean$S2)
ame_op_by_sex <- sapply(niv_sex, function(lv){
  sub <- df_clean; sub <- sub[sub$S2 == lv, ]
  p0 <- predict(modelo_final, newdata = sub, type = "response")
  sub2 <- sub; sub2$orient_precio <- sub2$orient_precio + 1
  p1 <- predict(modelo_final, newdata = sub2, type = "response")
  mean(p1 - p0)
})
ame_op_by_sex
```

```
## Masculino Femenino
## 0.11004765 0.02353574
```

```
# Orient_precio x Sexo
df_op_sex <- tibble(
  Sexo = niv_sex,
```

```

ame = ame_op_by_sex
)

ggplot(df_op_sex, aes(x = Sexo, y = ame)) +
  geom_col(alpha = 0.8) +
  coord_flip() +
  labs(
    title = "AME de orient_precio según sexo",
    x      = "Sexo",
    y      = "Var p(showrooming) por +1 orient_precio"
  ) +
  theme_minimal()

```

